Срезы, снимки состояния, предикаты

Илья Кокорин

kokorin.ilya.1998@gmail.com

Мотивирующий пример

- Сохраняем снимок состояния на диск
- При сбое повторяем вычисление не с самого начала
- А с момента снимка

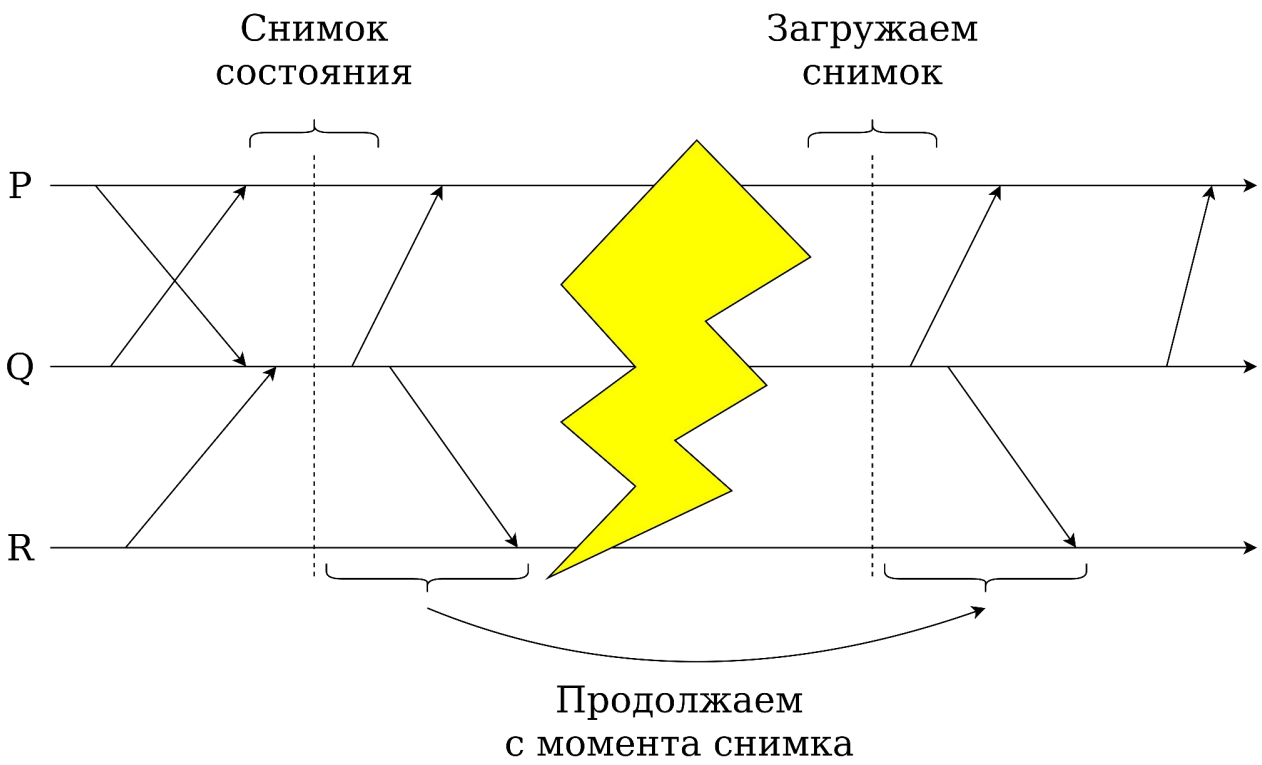

Наивный алгоритм

- Инициатор рассылает всем процессам команду “Сделать снимок”
- Получив команду, процесс сохраняет своё состояние
- Работает корректно?

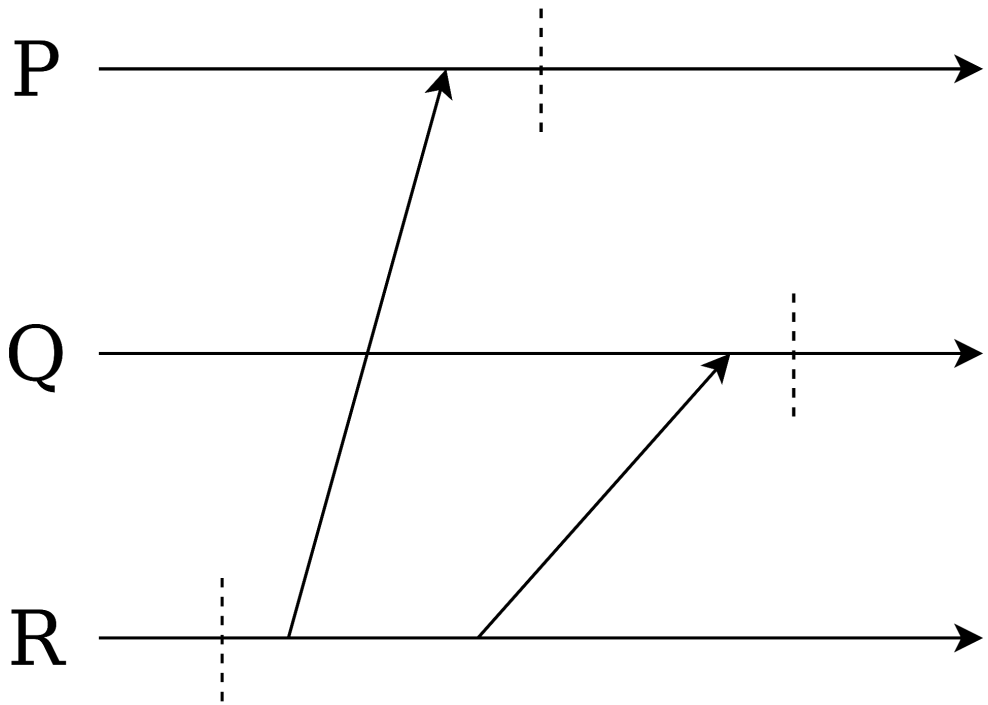

Наивный алгоритм

- Состояние меняется дважды
- Отправка сообщения `x += 1` не попала в снимок
  - Но попало получение

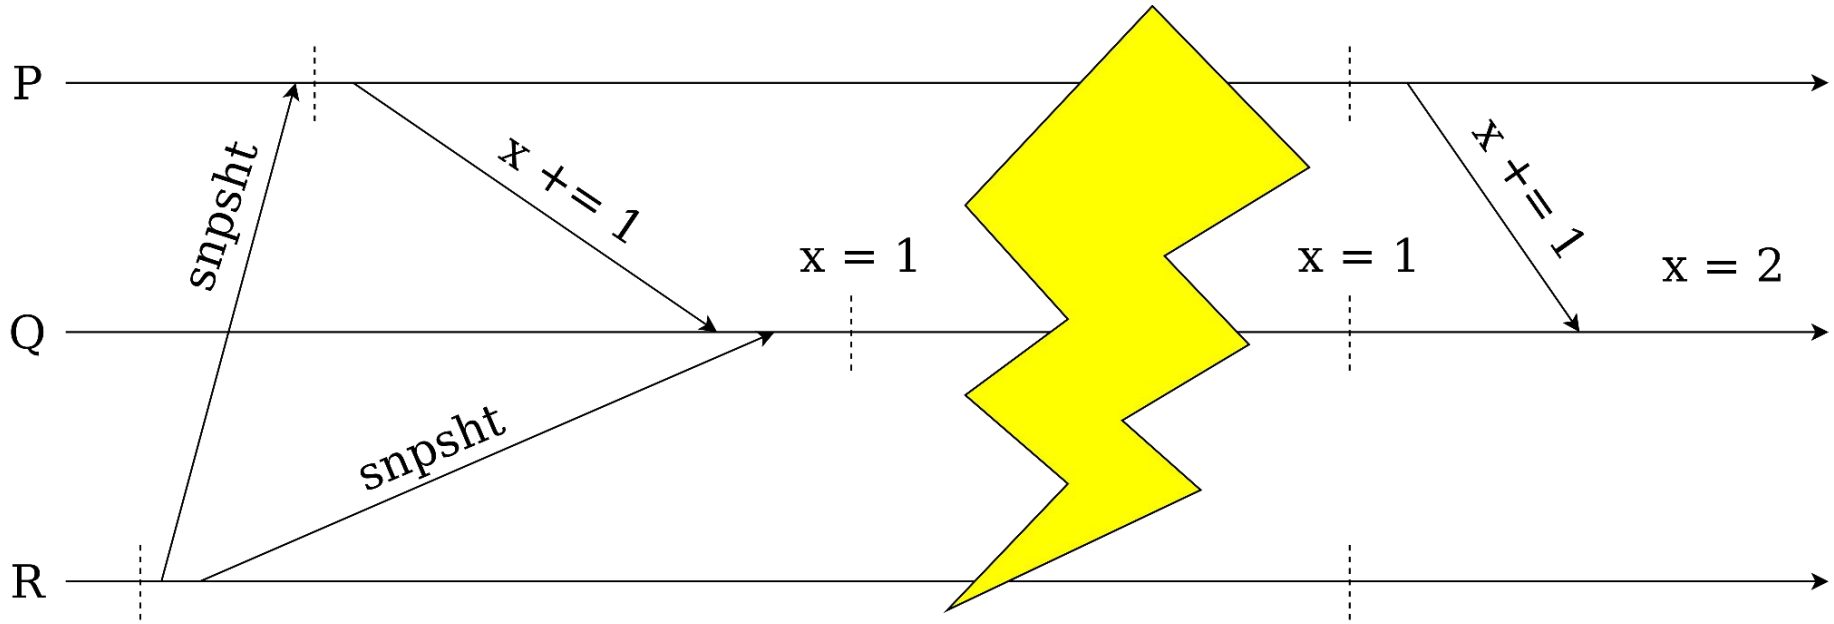

Срез: определение

- $S \subset \mathbb{E}$ называется срезом, если

$$\forall x, y \in \mathbb{E} : proc(x) = proc(y), x < y, y \in S \Rightarrow x \in S$$

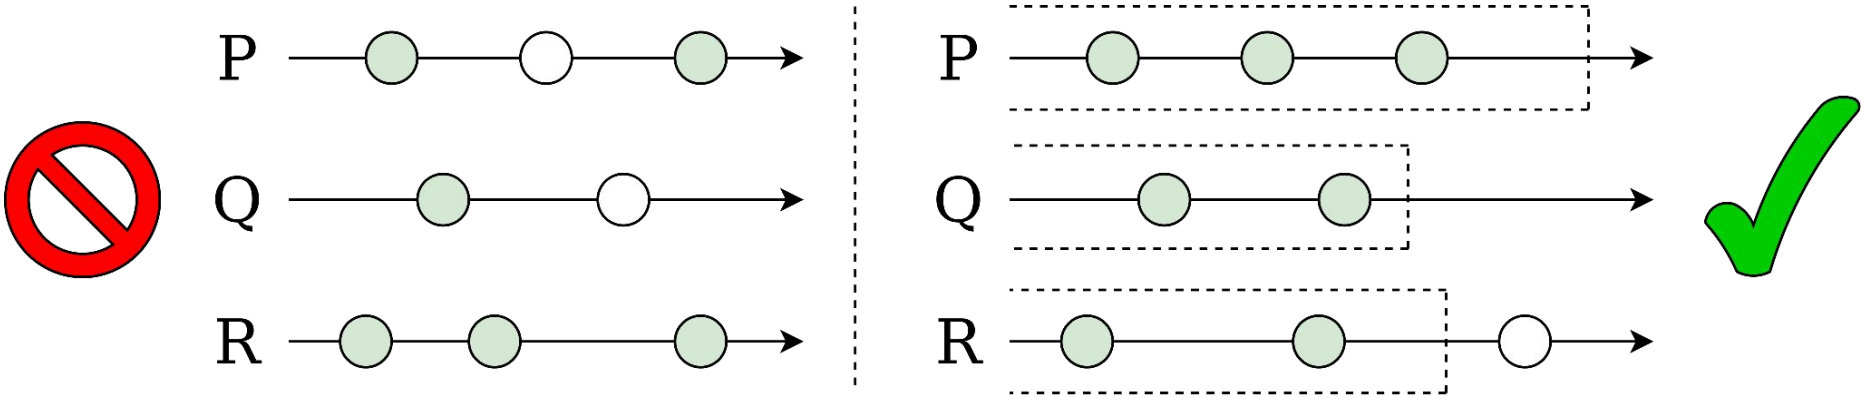

- На каждом процессе выбираем точку
- Все события левее этой точки входят в срез

Согласованный срез: определение

- Срез S называется согласованным срезом, если

$$\forall x, y \in \mathbb{E} : x \to y, y \in S \Rightarrow x \in S$$

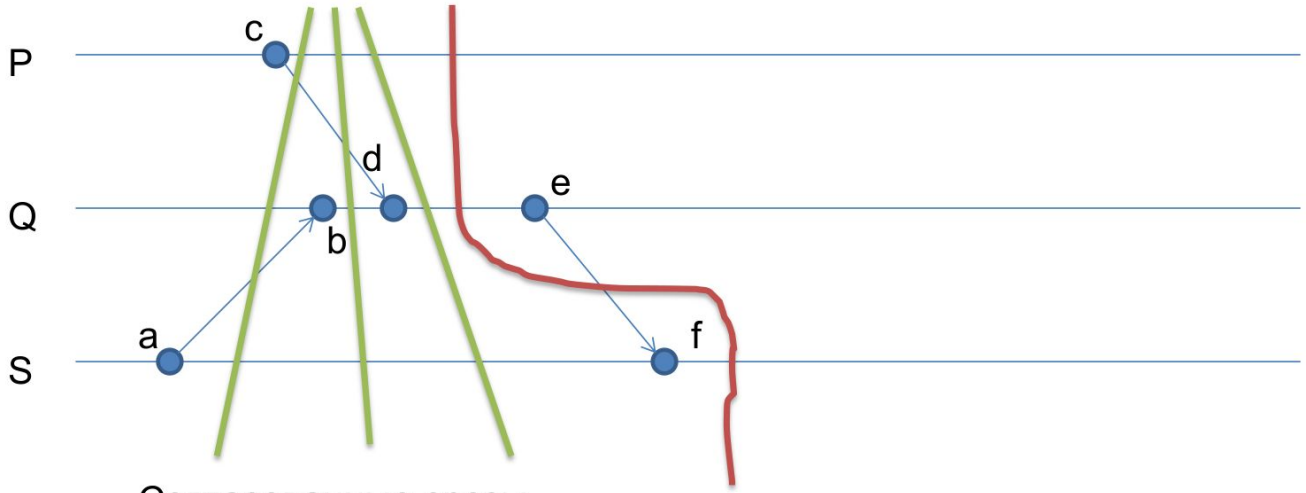

Согласованные срезы

Несогласованный срез

Алгоритм Чанди и Лампорта

- Процесс-инициатор решает, что хочет сделать снимок состояния
- Делает снимок
- Рассылает маркер своим соседям

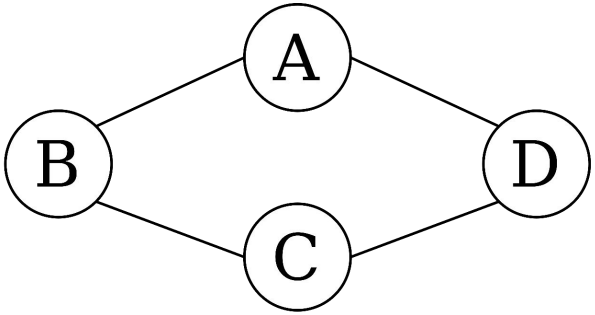

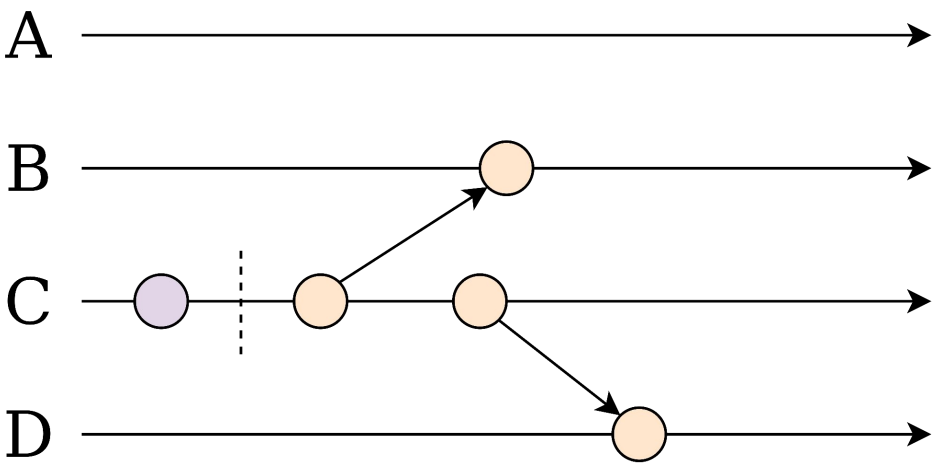

Алгоритм Чанди и Лампорта

- Получив маркер, процесс сохраняет состояние
- И рассылает маркер соседям
  - Можно не посылать тому, от кого пришёл запрос
- Если ещё не сохранял состояние до этого

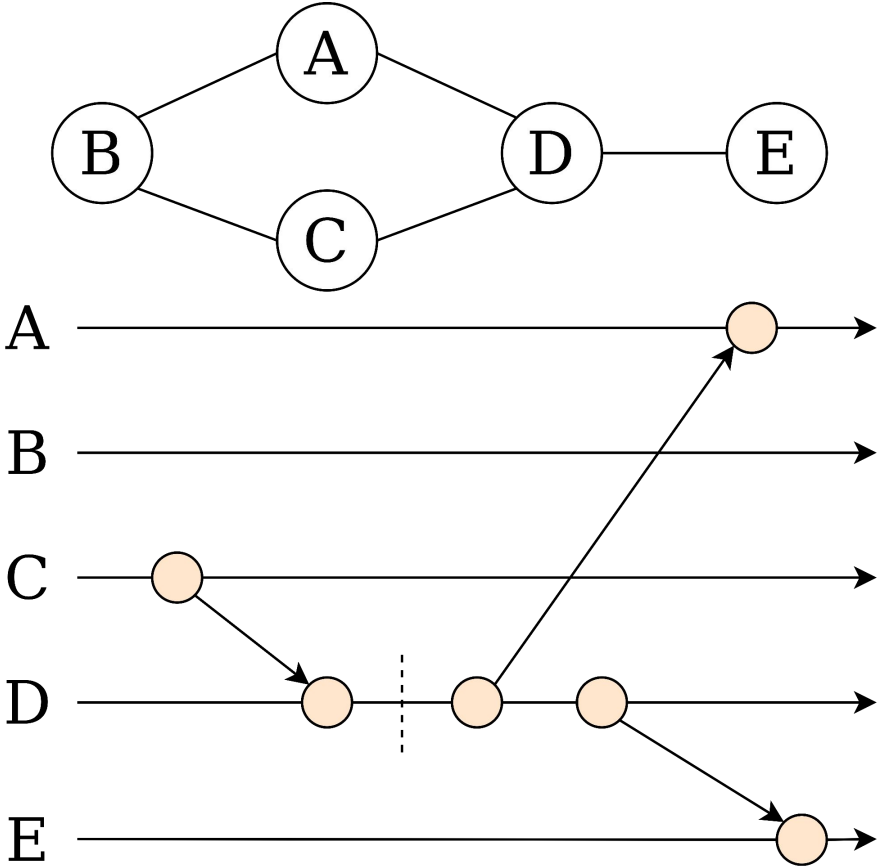

Алгоритм Чанди и Лампорта

- Если процесс уже сохранял состояние, он игнорирует дальнейшие маркеры

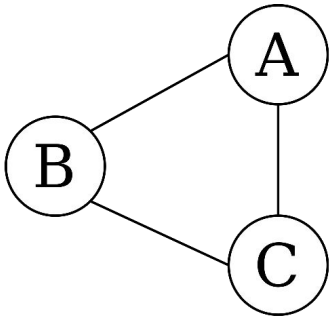

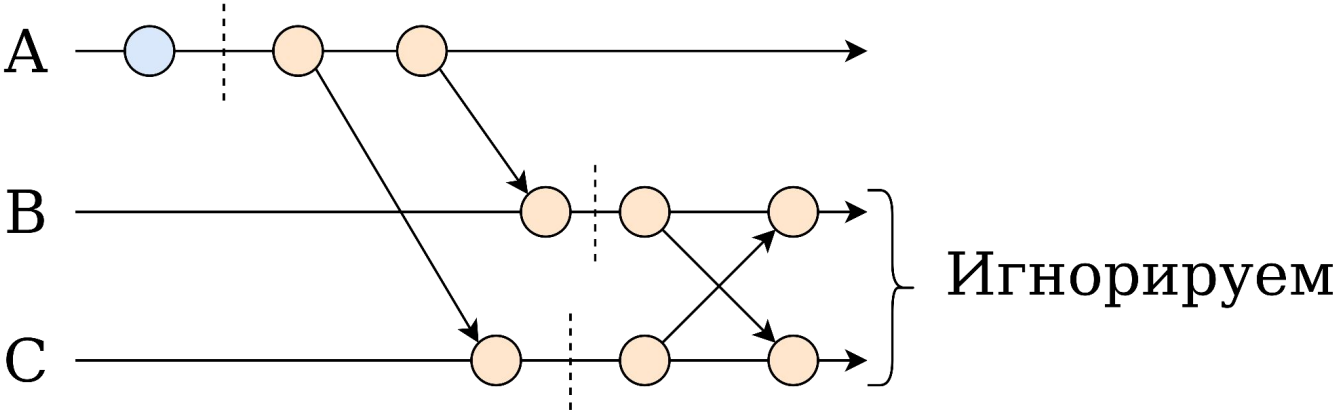

Алгоритм Чанди и Лампорта

- Может ли получиться несогласованный срез?

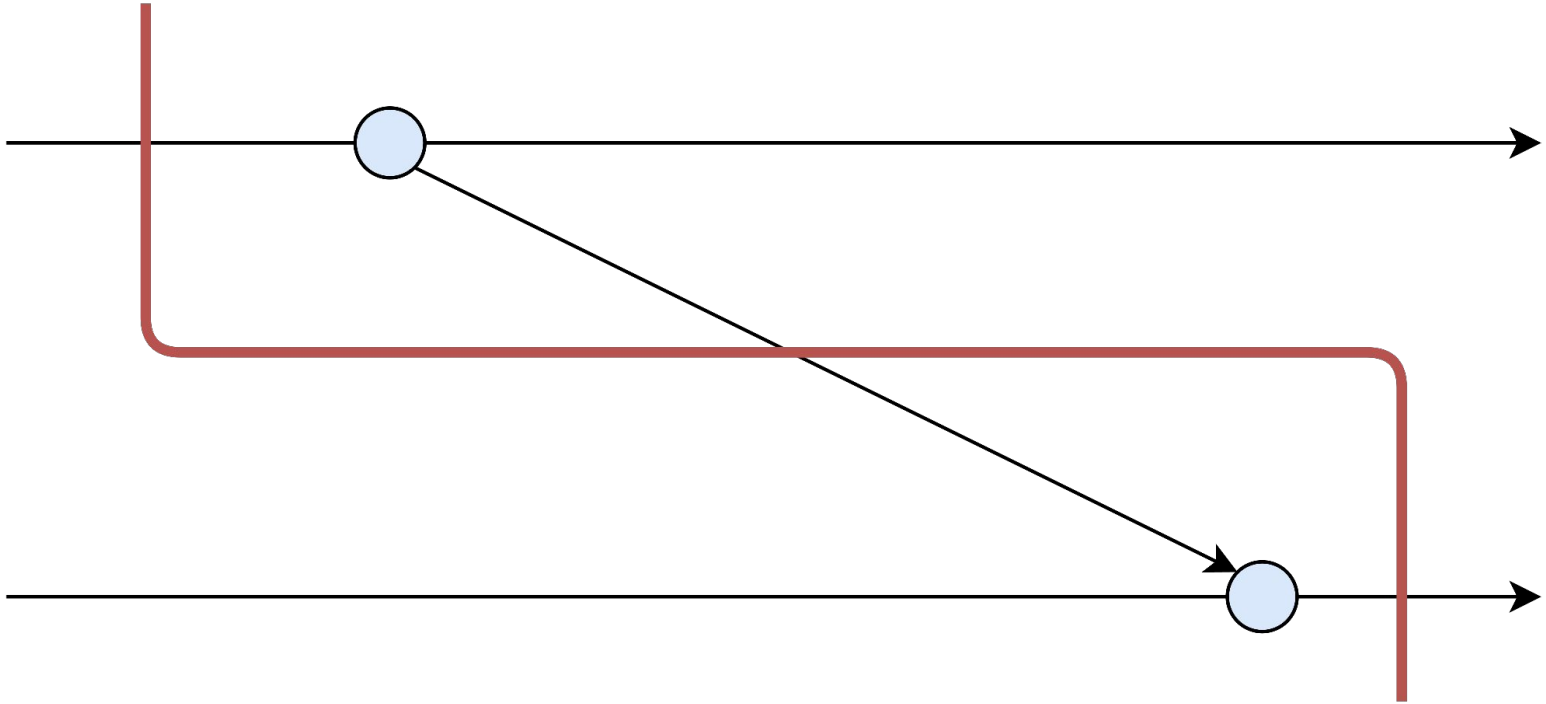

Алгоритм Чанди и Лампорта

- Нет, если сообщения идут FIFO

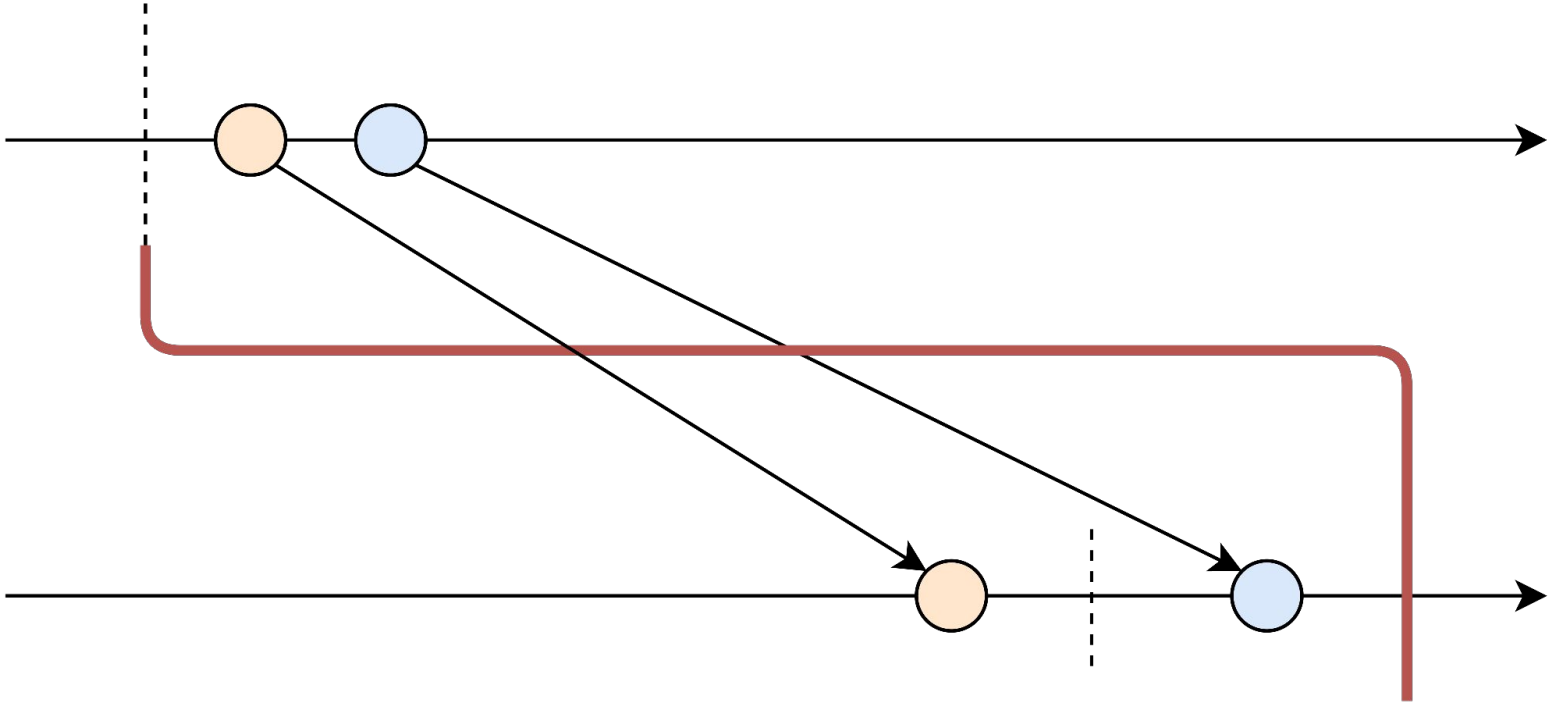

Сообщения в пути

- Сообщения в пути нужно сохранять
- Чтобы при восстановлении из снимка доставить их заново

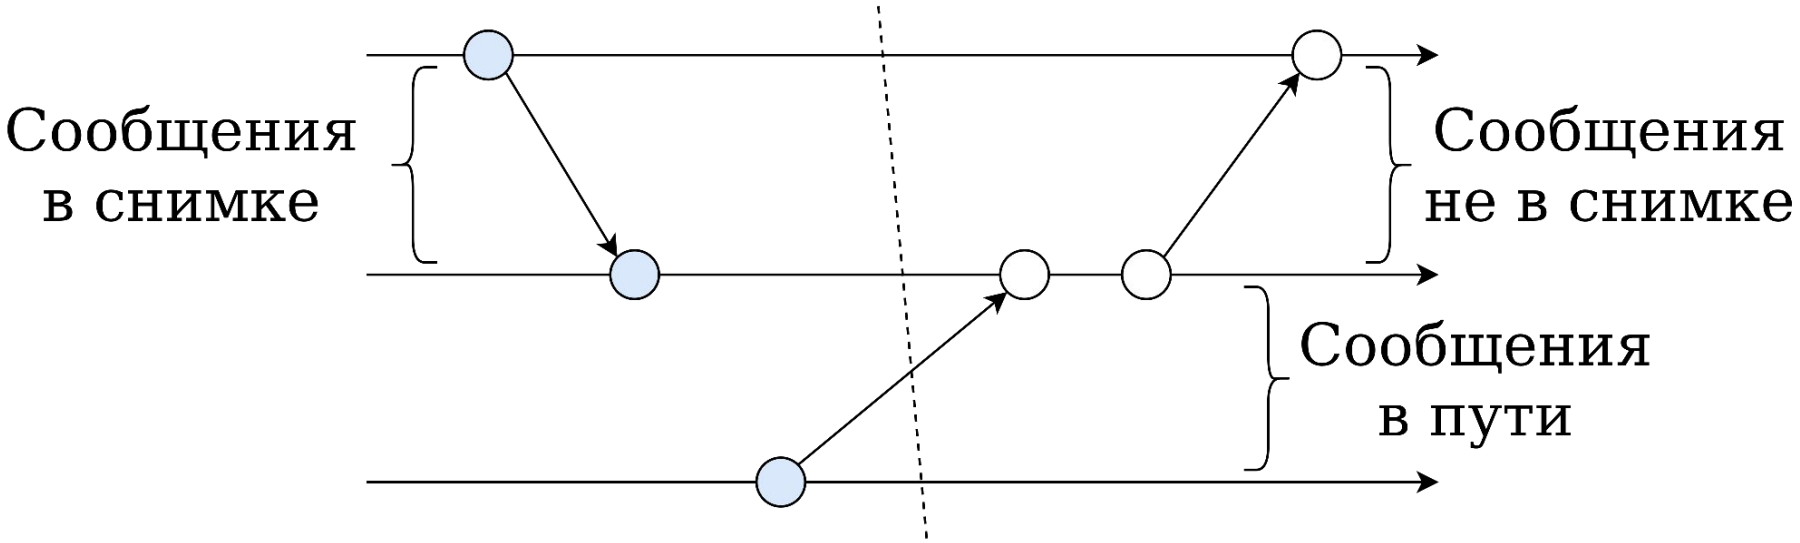

Запоминание на стороне отправителя

- Каждое отправленное сообщение запоминаем локально
  - Если мы пока не делали снимок
- Удаляем, получив подтверждение
- Получатель подтверждает получение каждого сообщения

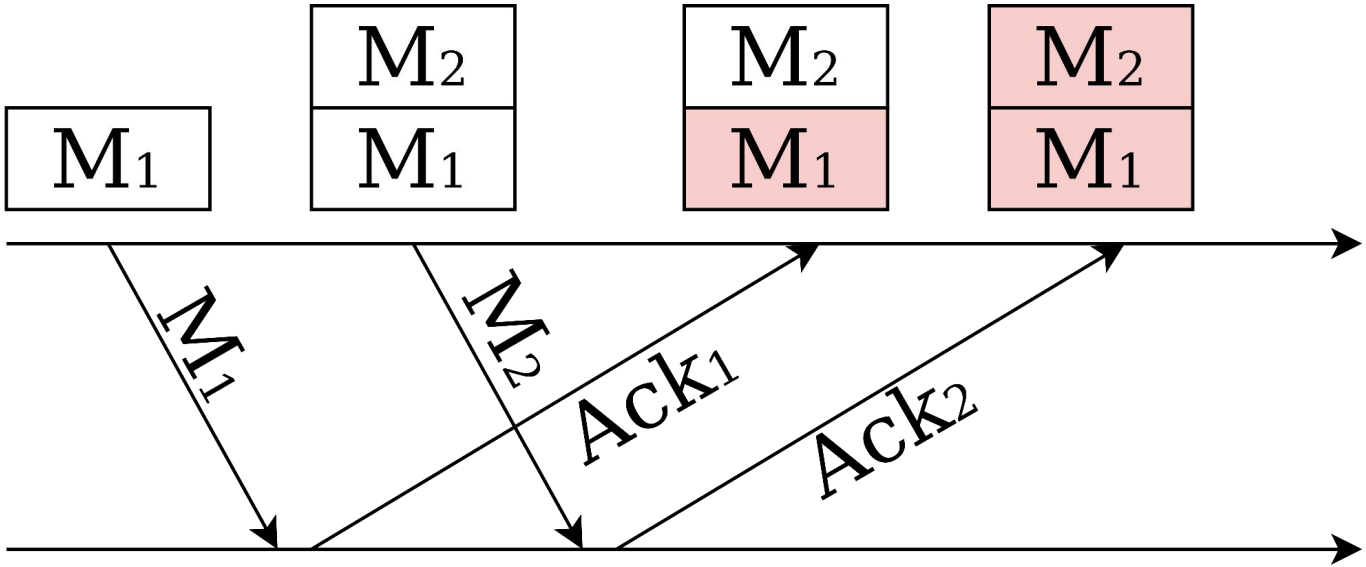

Запоминание на стороне отправителя

- Получив токен от процесса P, запоминаем все неподтверждённые сообщения в пути до P

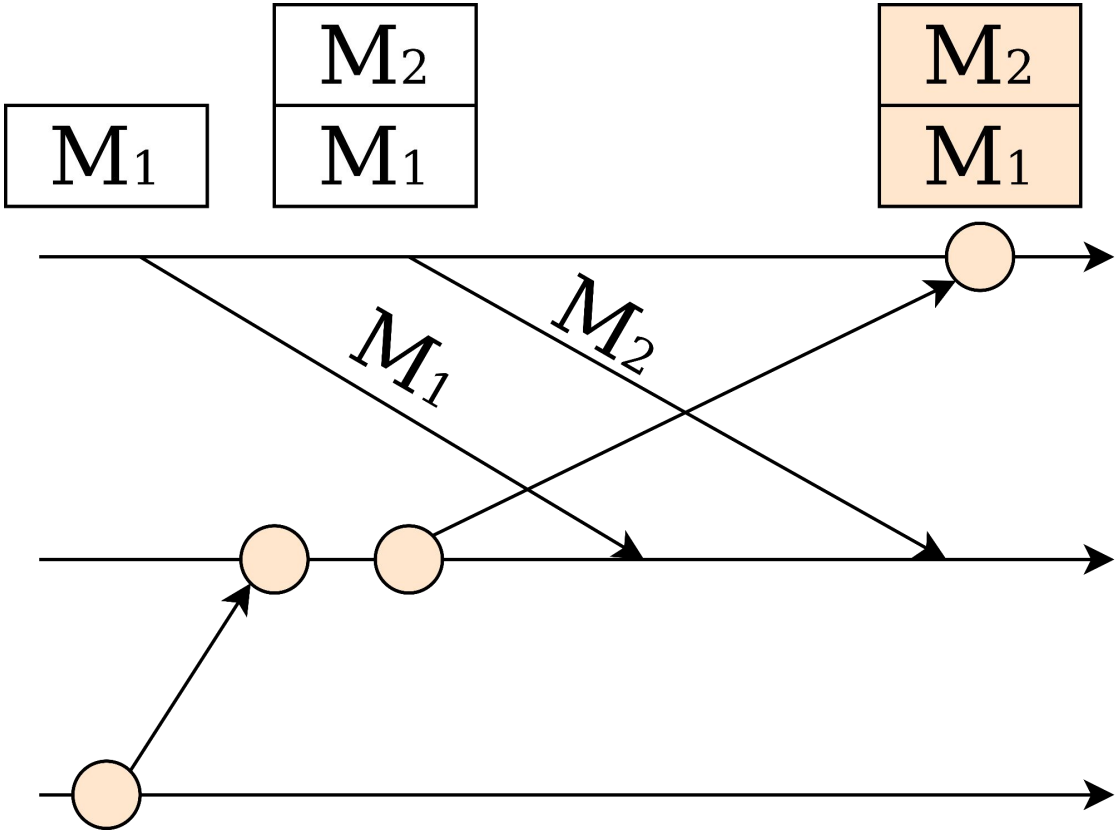

Запоминание на стороне отправителя

- Если сообщение было обработано до обработки токена - `Ack` придёт после токена
- Иначе - придёт после

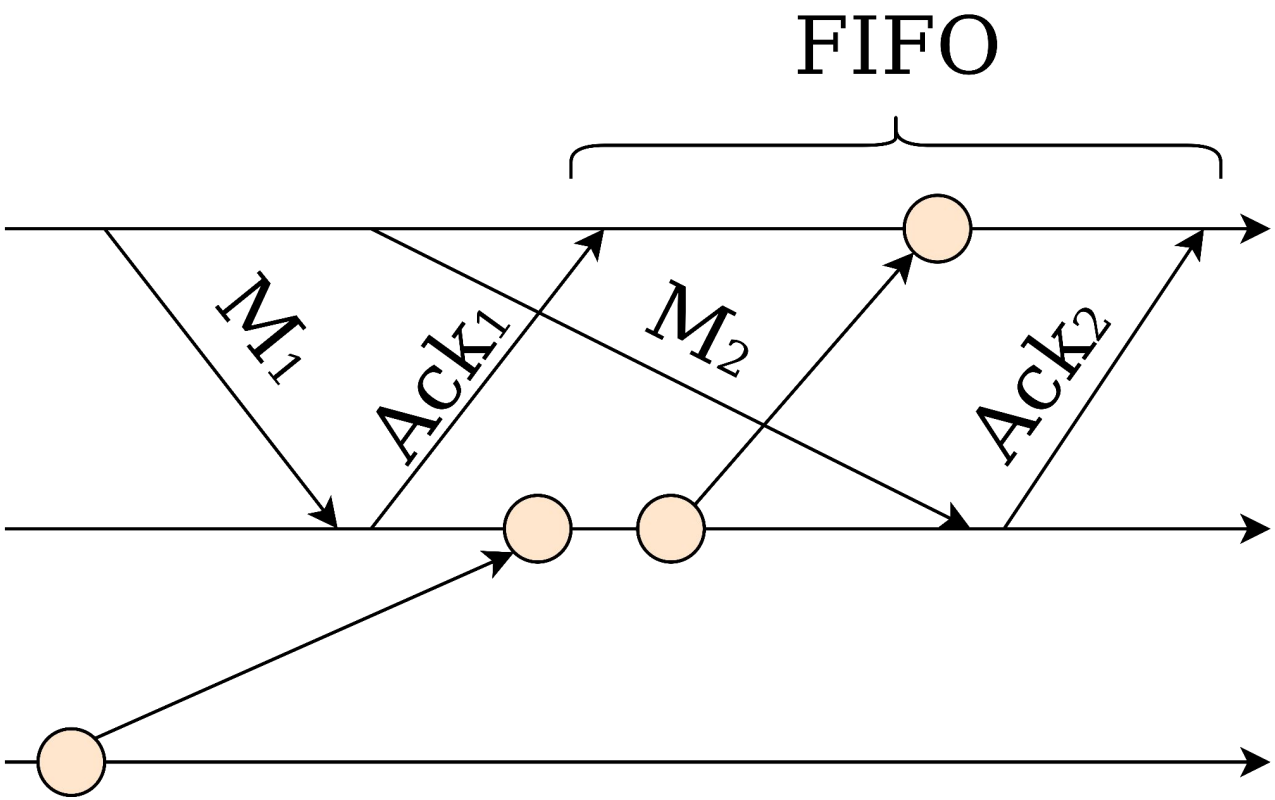

Запоминание на стороне отправителя

- После восстановления отправители перепосылают запомненные сообщения

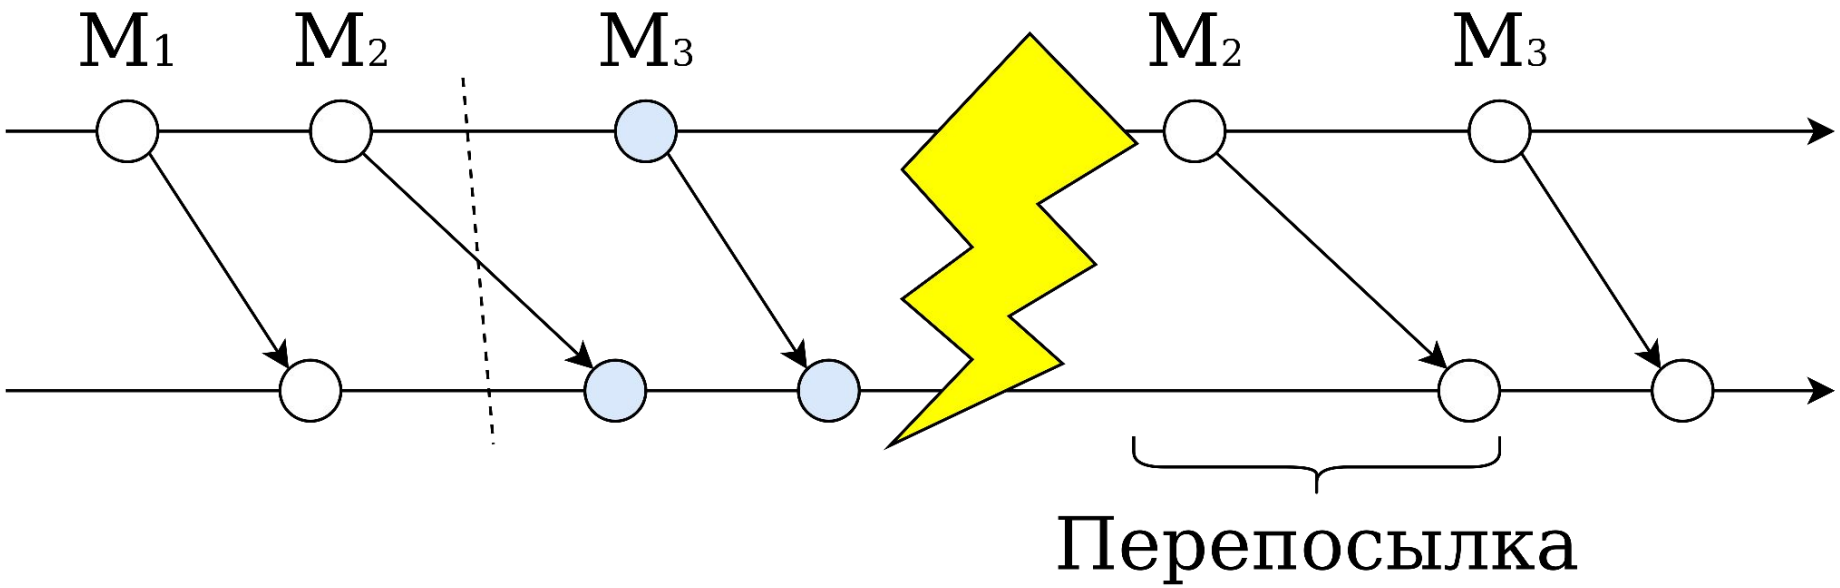

Запоминание на стороне получателя

- К каждому сообщению прикрепляем состояние отправителя
  - Сделал он уже снимок или ещё нет
- Получатель однозначно определяет, нужно ли сохранять состояние

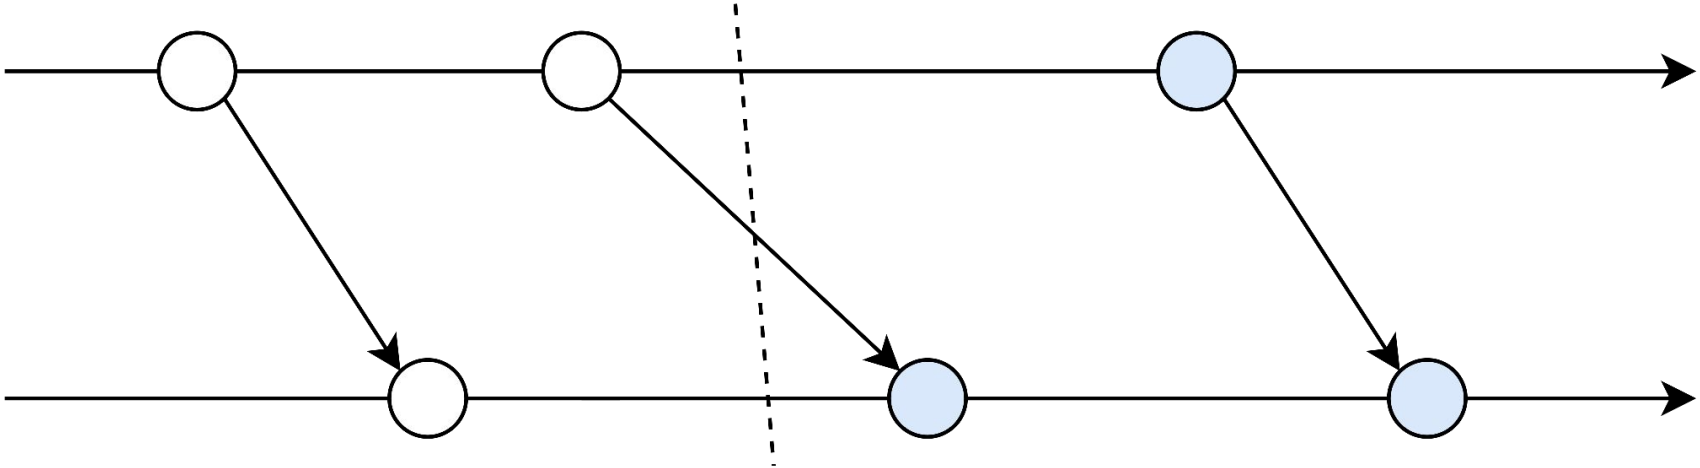

Запоминание на стороне получателя

- После восстановления получатели обрабатывают запомненные сообщения ещё раз

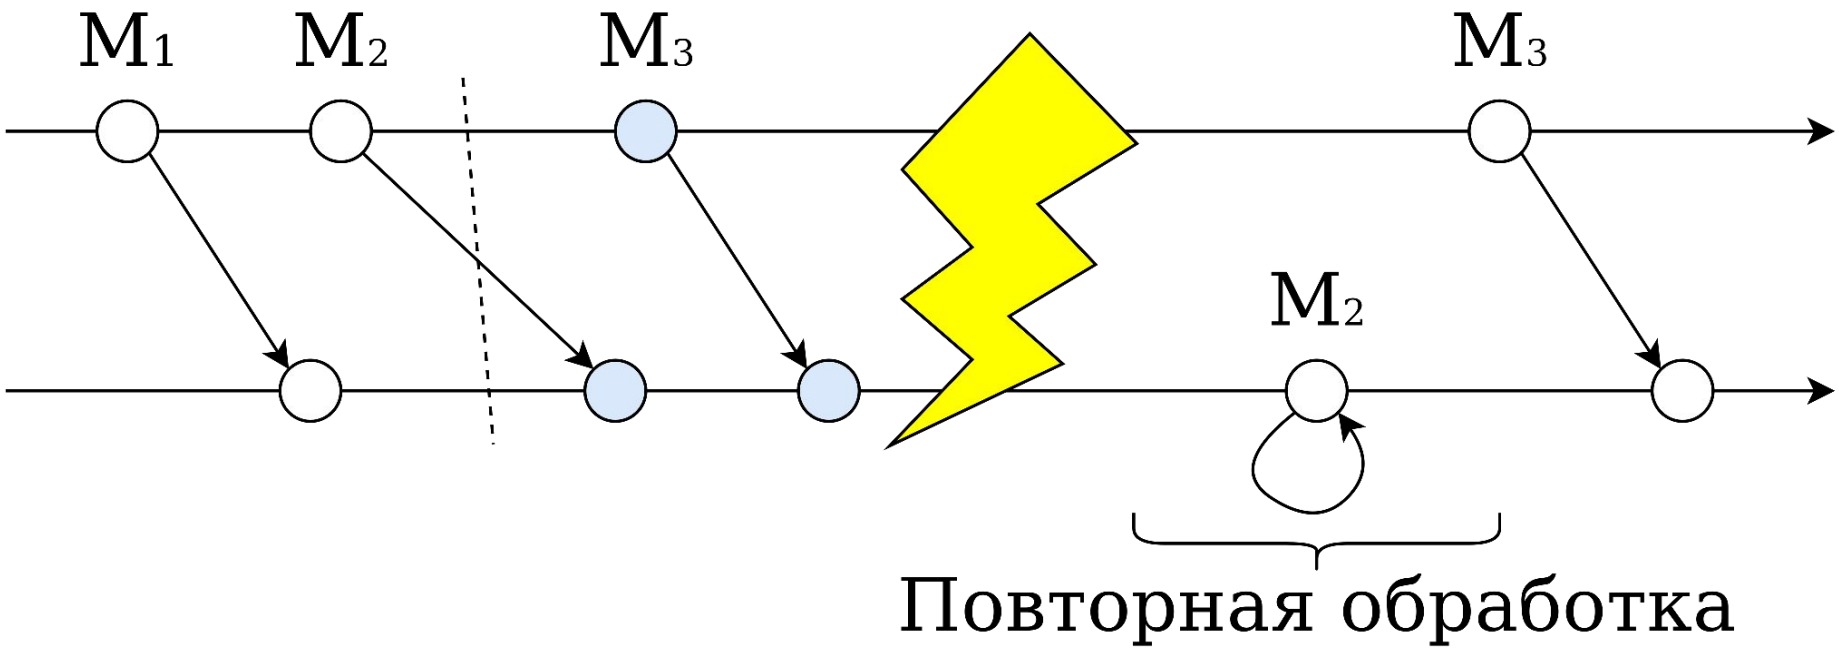

Предикаты

- Хотим уметь проверять что-то про систему
  - Не более одного процесса в КС
  - Токен ровно у одного процесса
  - Нет дедлока
- Можно ли проверять предикат тривиальным алгоритмом?

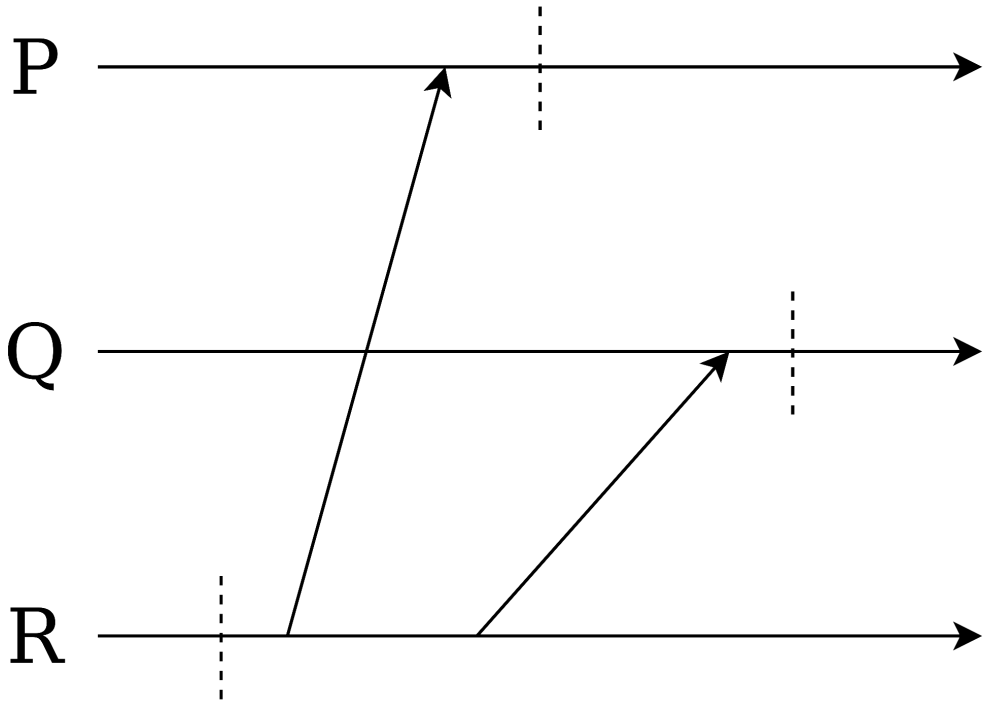

Предикаты

- Только на согласованном срезе
- $O(N^2)$ сообщений. Можно ли дешевле?

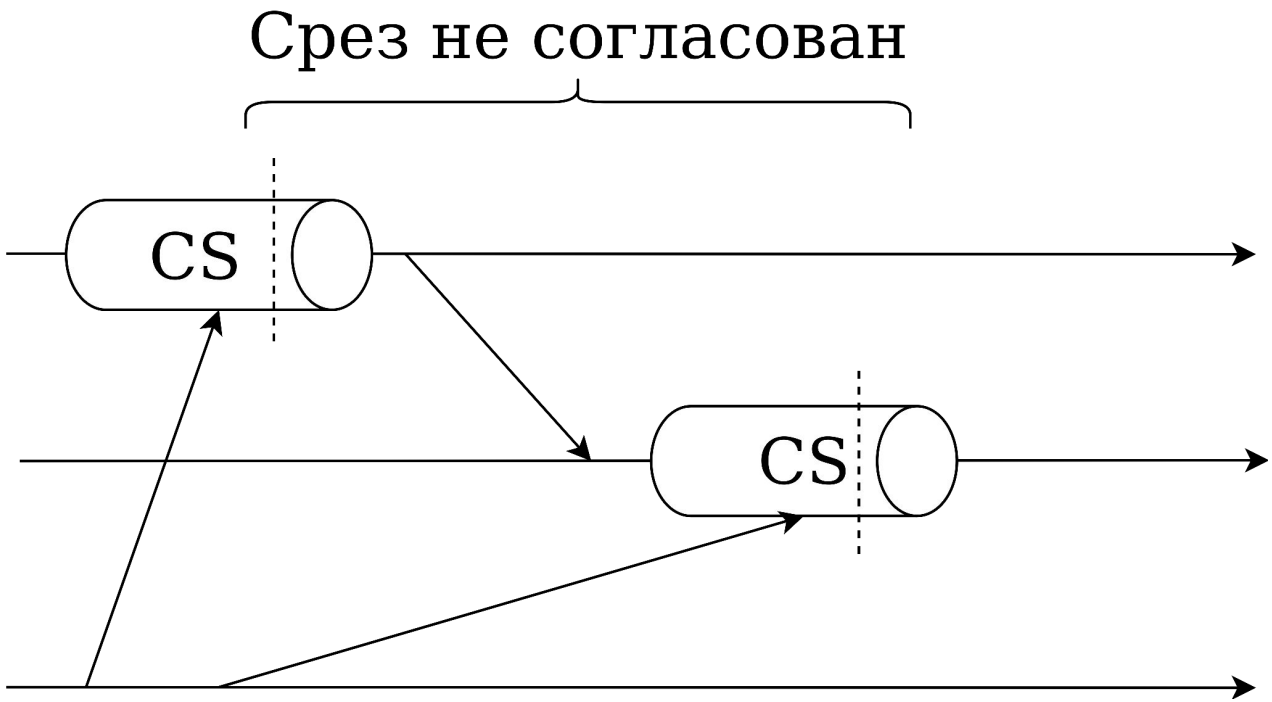

Распределённый алгоритм Дейкстры

- Кратчайший путь в ориентированном взвешенном графе
- Каждому процессу соответствует вершина графа
- От каждого процесса ищем кратчайшее расстояние до процесса-инициатора

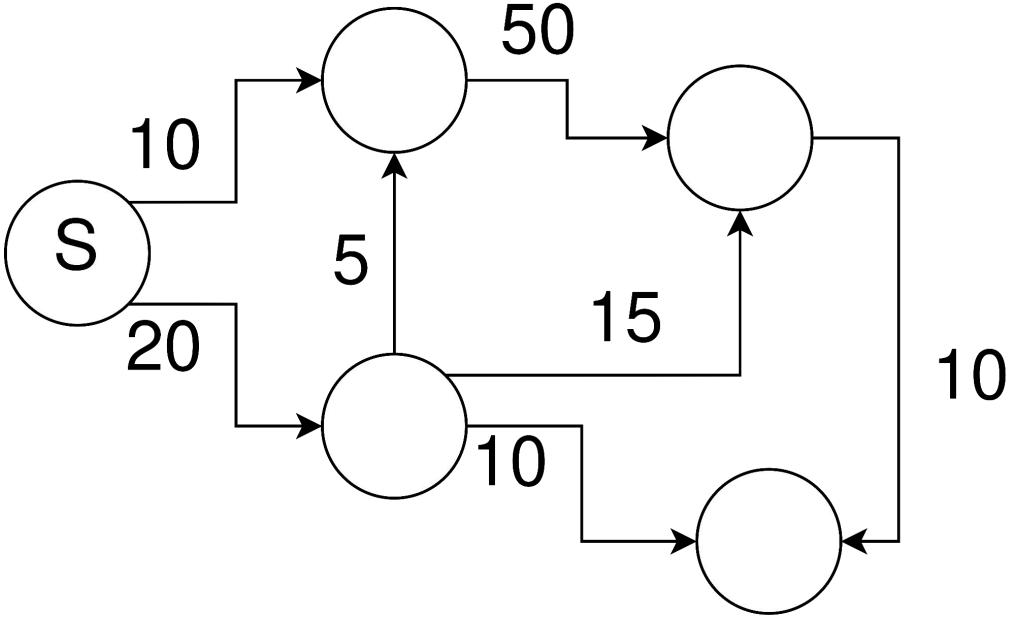

Распределённый алгоритм Дейкстры

- Расстояние от инициатора изначально равно нулю
- От остальных процессов равно бесконечности
- Инициатор рассылает всем **соседям** сообщение с расстоянием 0
- Похожим образом работает протокол RIP

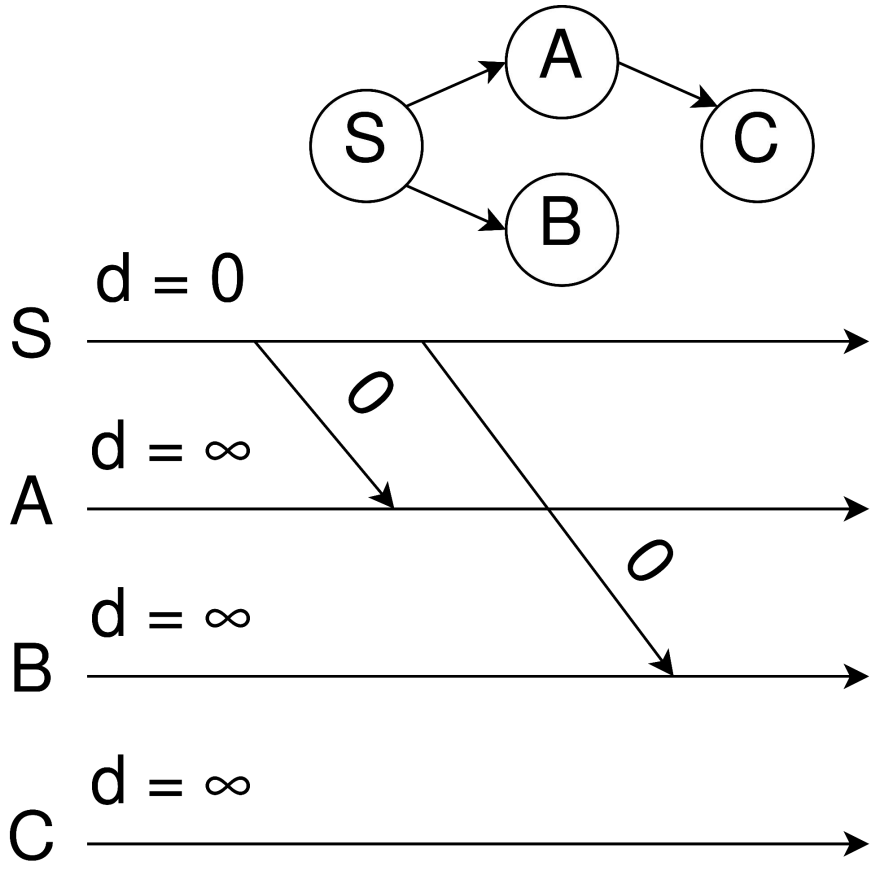

Распределённый алгоритм Дейкстры

- Получив сообщение с расстоянием d_n по ребру весом e, релаксируем
  $d = \min(d, d_n + e)$
- Если расстояние уменьшилось, рассылаем его всем соседям

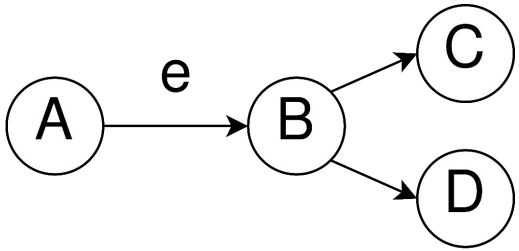

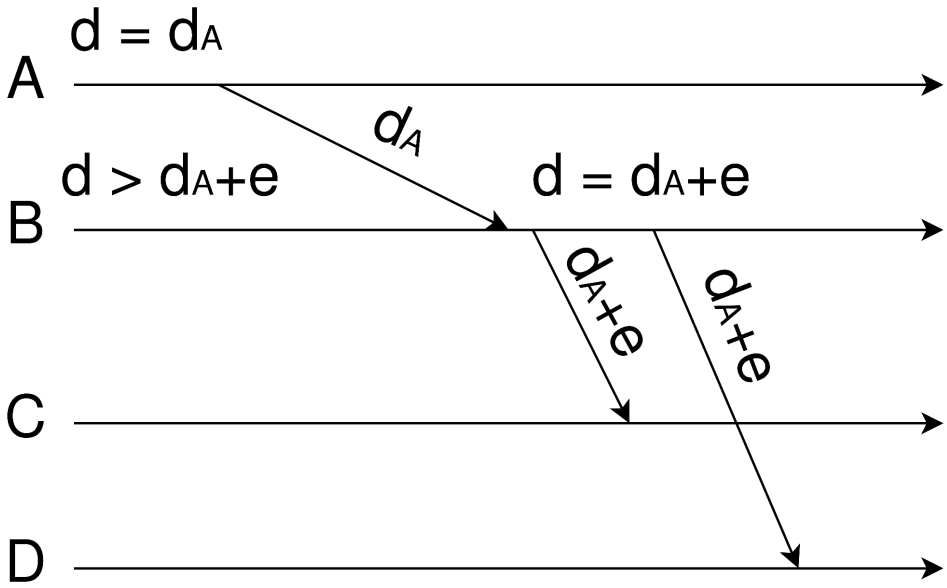

Распределённый алгоритм Дейкстры

- Получив сообщение с расстоянием d_n по ребру весом e, релаксируем
  $d = \min(d, d_n + e)$
- Если расстояние не уменьшилось, ничего не делаем

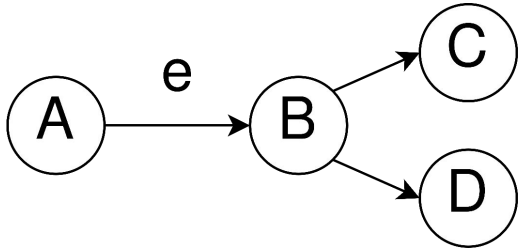

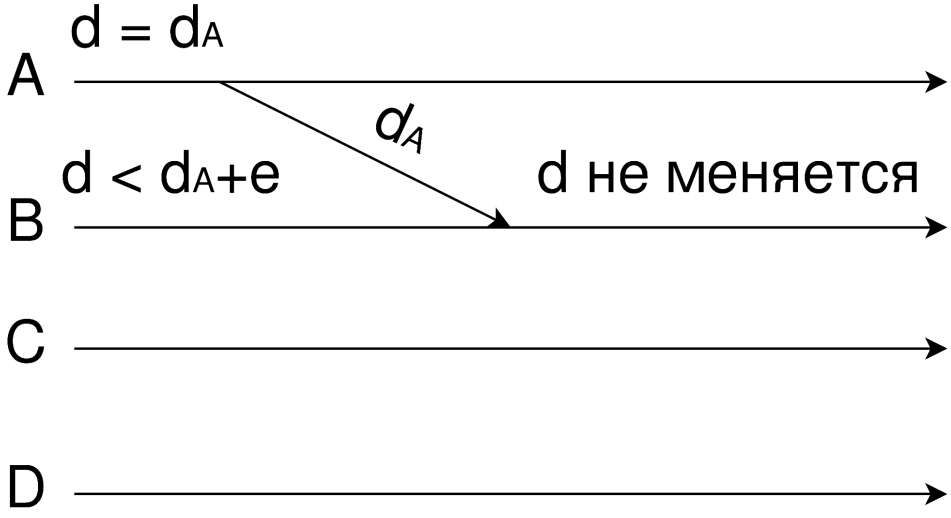

Распределённый алгоритм Дейкстры

- Алгоритм находит все кратчайшие пути
- И завершается
  - Расстояния не релаксируются
  - Значит, никто не рассылает новое расстояние

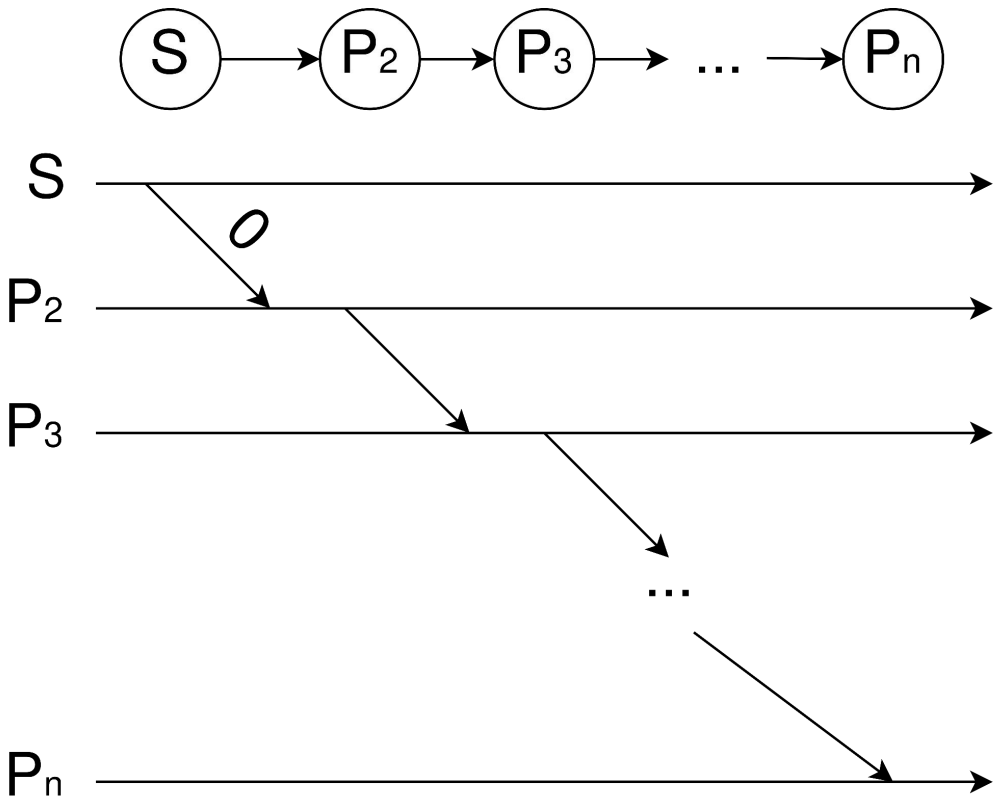

Диффундирующие вычисления

- Каждый процесс может быть либо активен, либо пассивен
- Только активный процесс может посылать сообщения
- Пассивный процесс становится активным, получив сообщение
- Активный процесс может в любой момент стать пассивным
- Изначально есть один активный процесс — инициатор

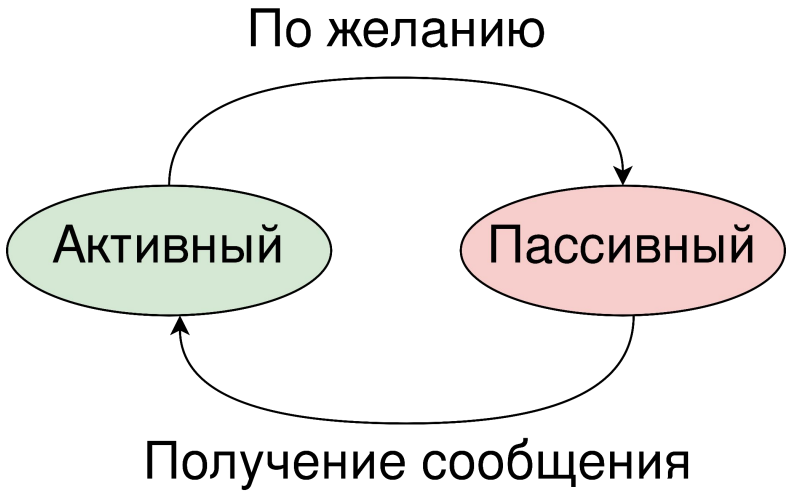

Диффундирующие вычисления

- Вычисление завершилось когда все процессы пассивны
- И нет сообщений в пути
- В противном случае даже согласованность среза не гарантирует нам останов вычисления

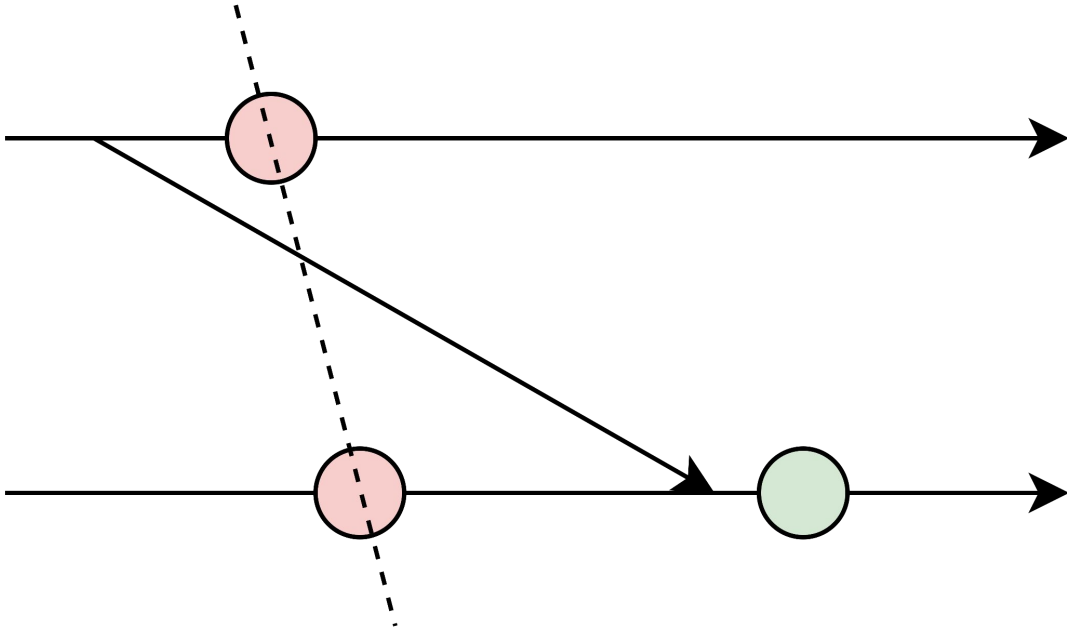

Алгоритм Дейкстры и Шолтена

- Выстраиваем некоторые процессы в дерево
- В дереве могут быть активные и пассивные процессы
- Остальные процессы свалены в кучу
- Только пассивные

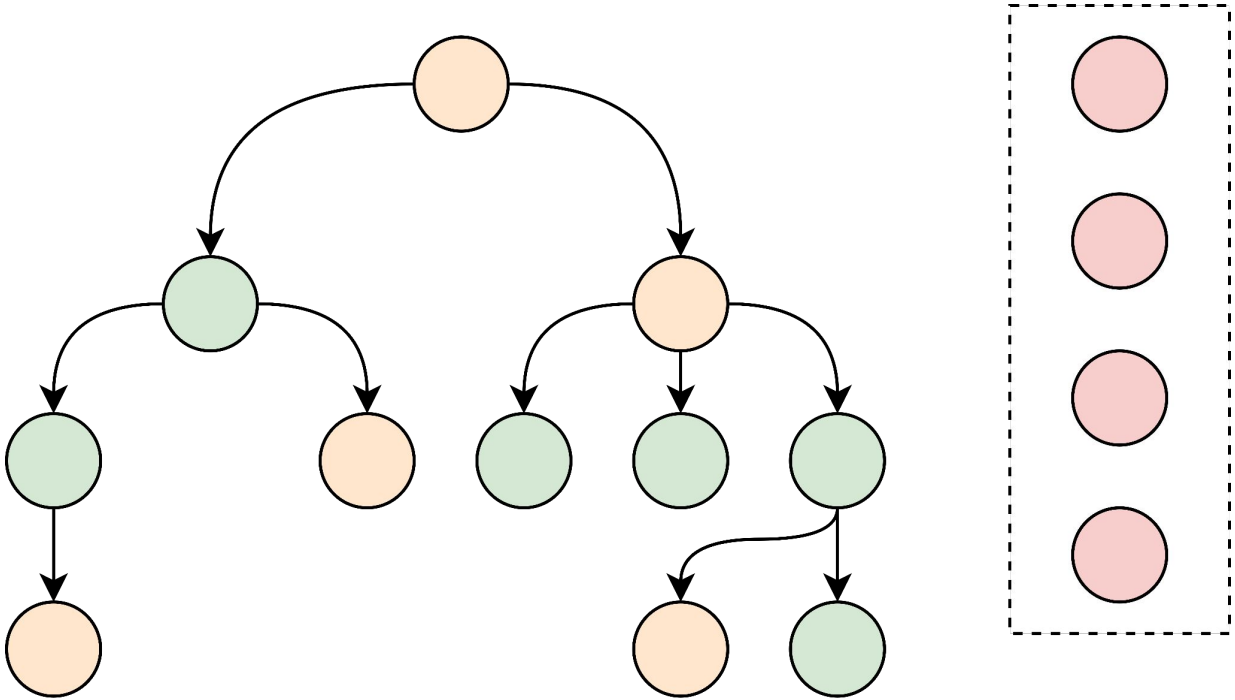

Алгоритм Дейкстры и Шолтена

- На каждое сообщение высылается подтверждение
- Каждый активный процесс считает количество неподтверждённых сообщений

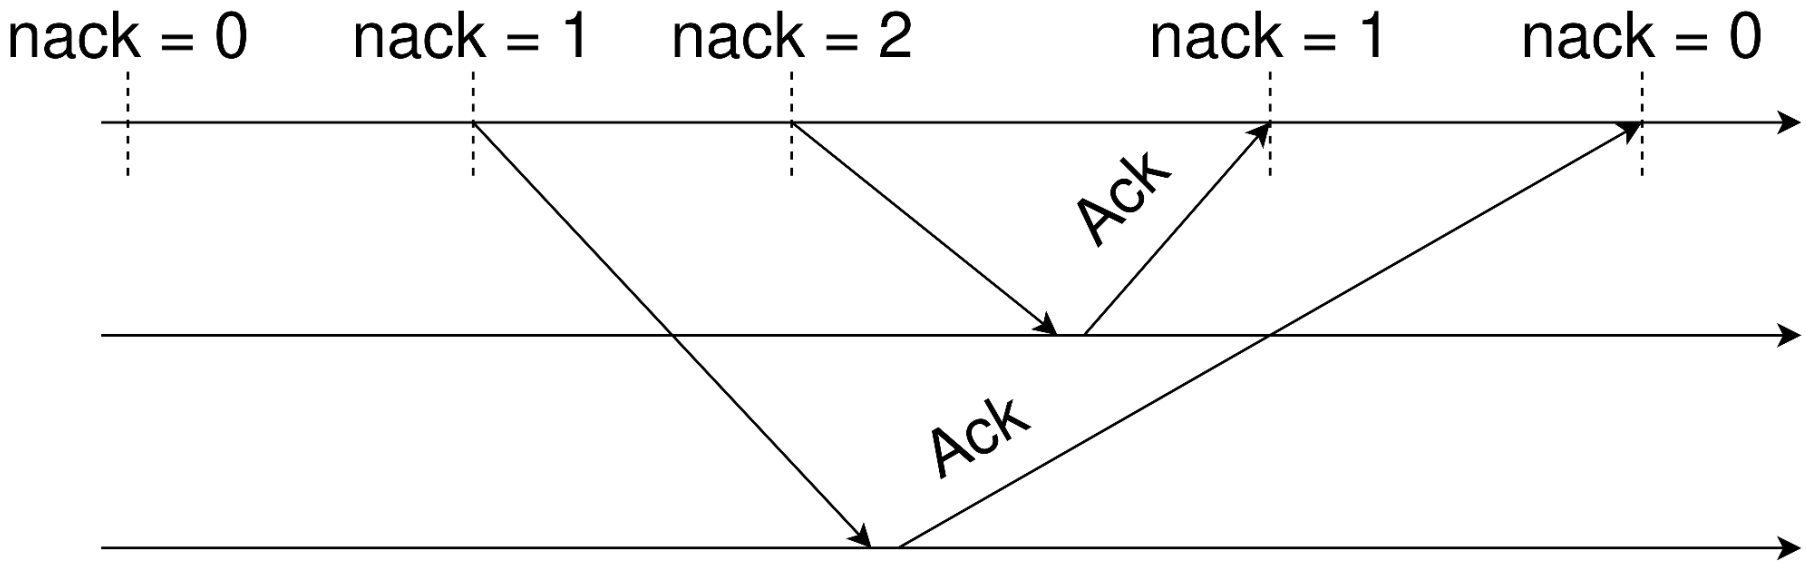

Алгоритм Дейкстры и Шолтена

- Если процесс из кучи получает сообщение, он становится ребёнком отправителя в дереве
- Вместо `Ack` посылает сообщение `ChildAck`

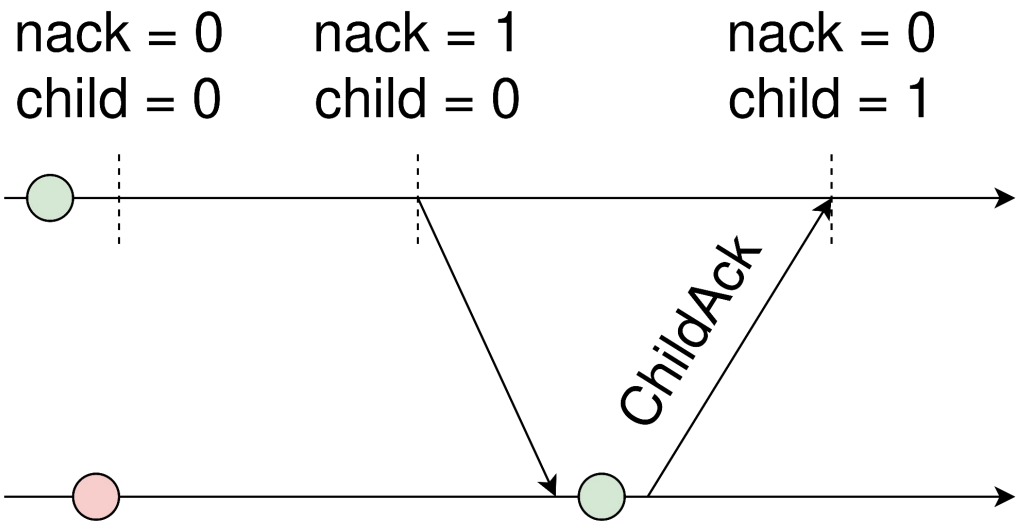

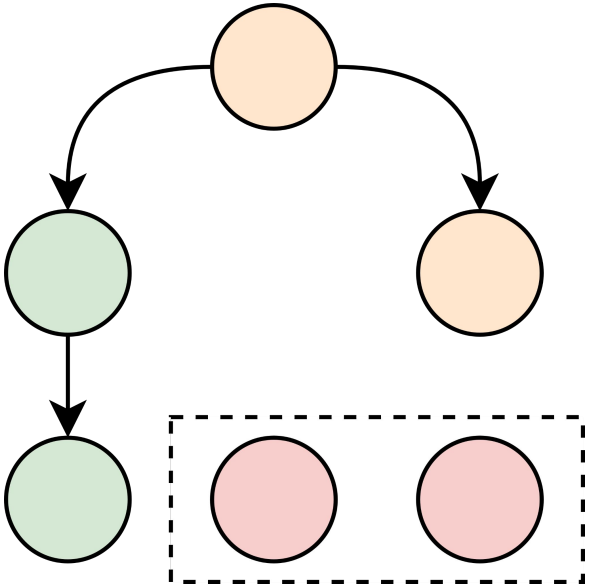

Алгоритм Дейкстры и Шолтена

- Дерево нигде не хранится централизованно
- Просто каждый процесс помнит своего родителя

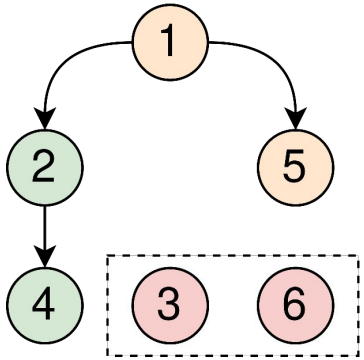

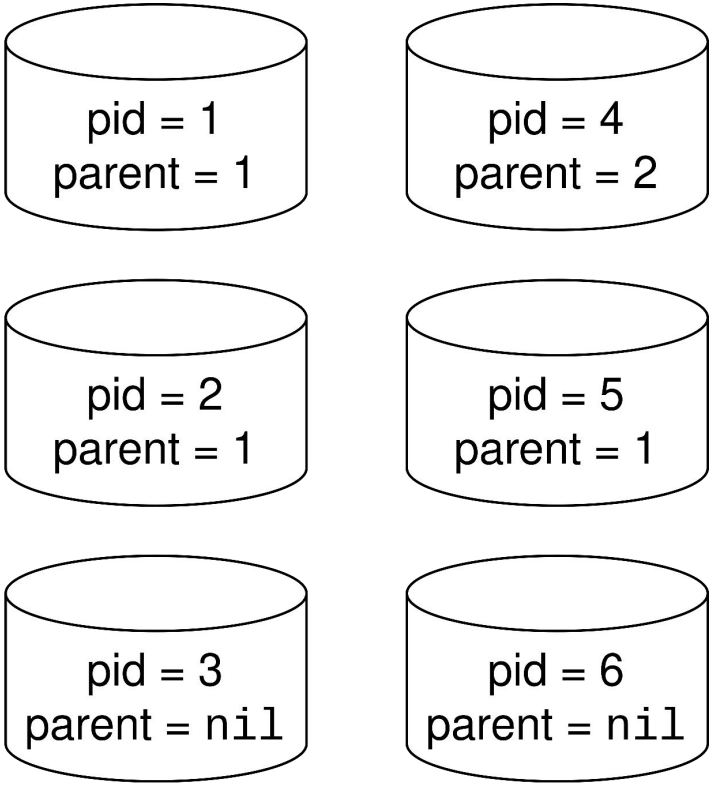

Алгоритм Дейкстры и Шолтена

- Процесс может выйти из дерева если он:
  - Пассивен
  - Не имеет детей
  - Не имеет неподтверждённых сообщений
- Посылает родителю сообщение `ChildStop`
- Родитель уменьшает число детей

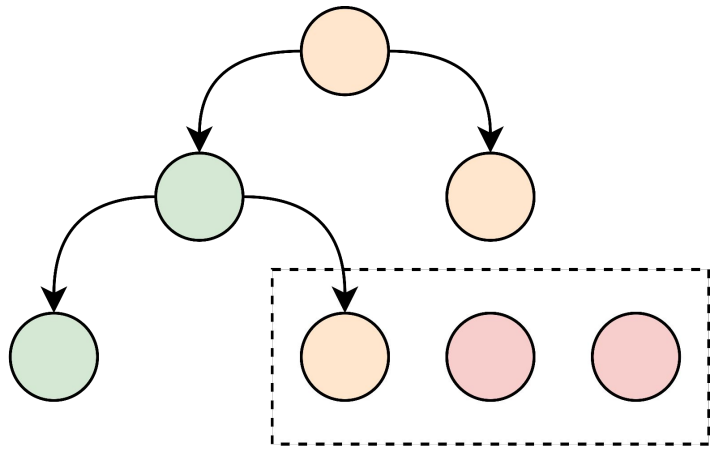

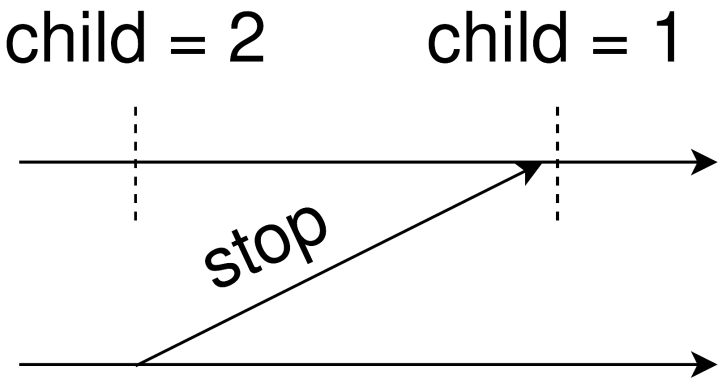

Алгоритм Дейкстры и Шолтена

- Изначально в дереве находится только корень (Процесс-инициатор)

- Алгоритм завершается как только корень выходит из дерева

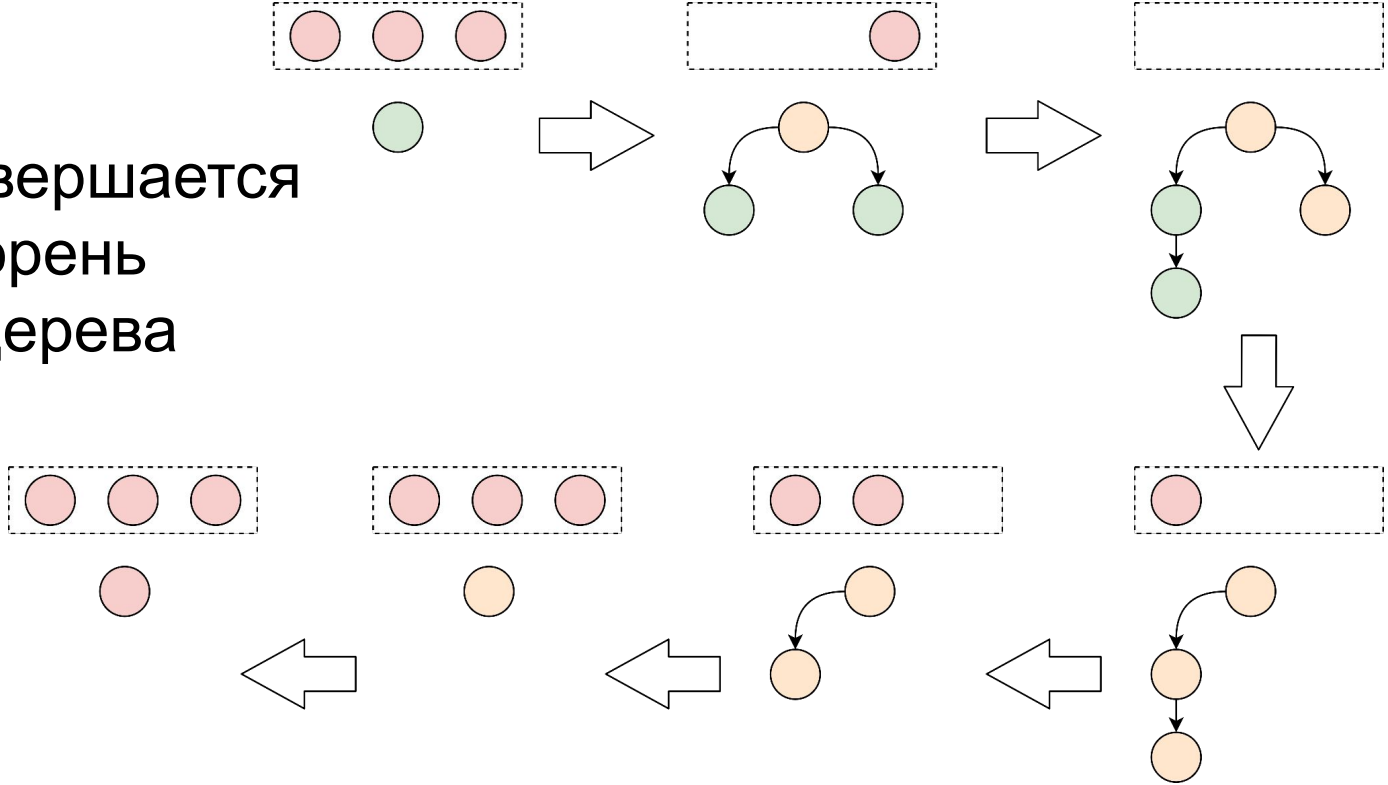

Согласованные интервалы

- Пара срезов $F, G \subset E$ называется интервалом, если $F \subset G$
- Обозначаем [F, G]

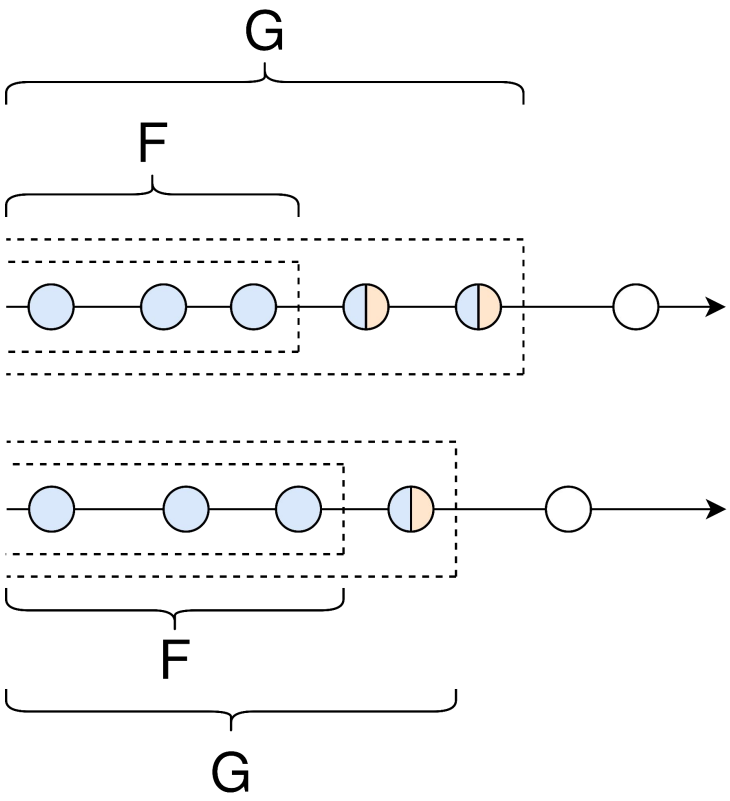

Согласованные интервалы

- Интервал [F, G] называется согласованным, если

$$\forall x \in E, y \in F : x \to y \Rightarrow x \in G$$

- Эквивалентно $\nexists x \in E \setminus G, y \in F : x \to y$

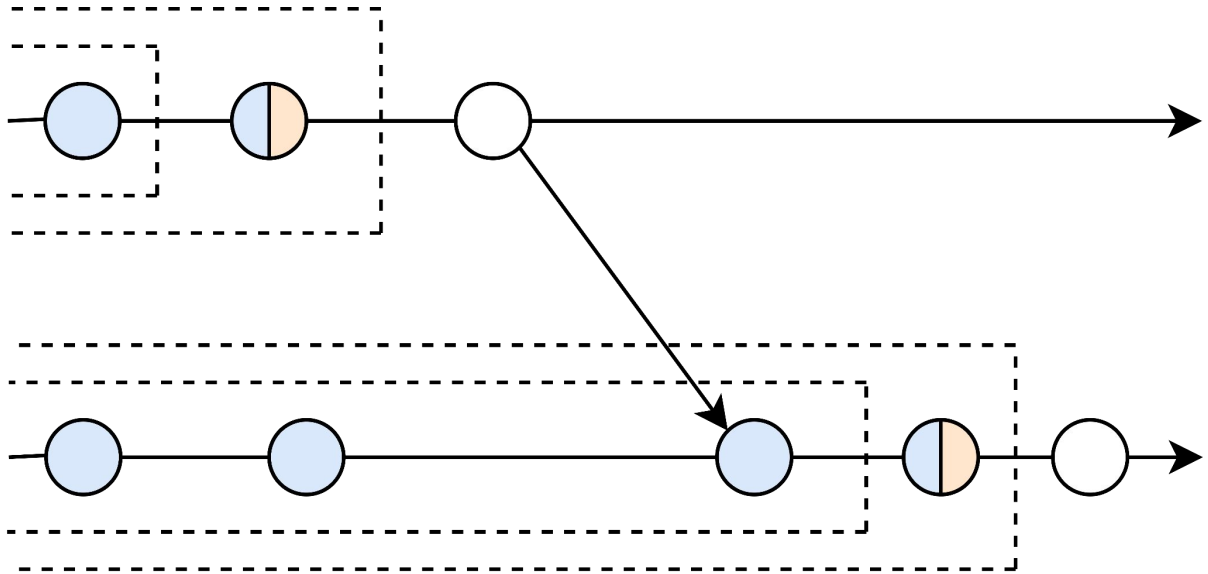

Согласованные интервалы

- **Теорема**: интервал [F, G] согласован тогда и только тогда, когда внутри него существует согласованный срез H

$$F \subset H \subset G$$

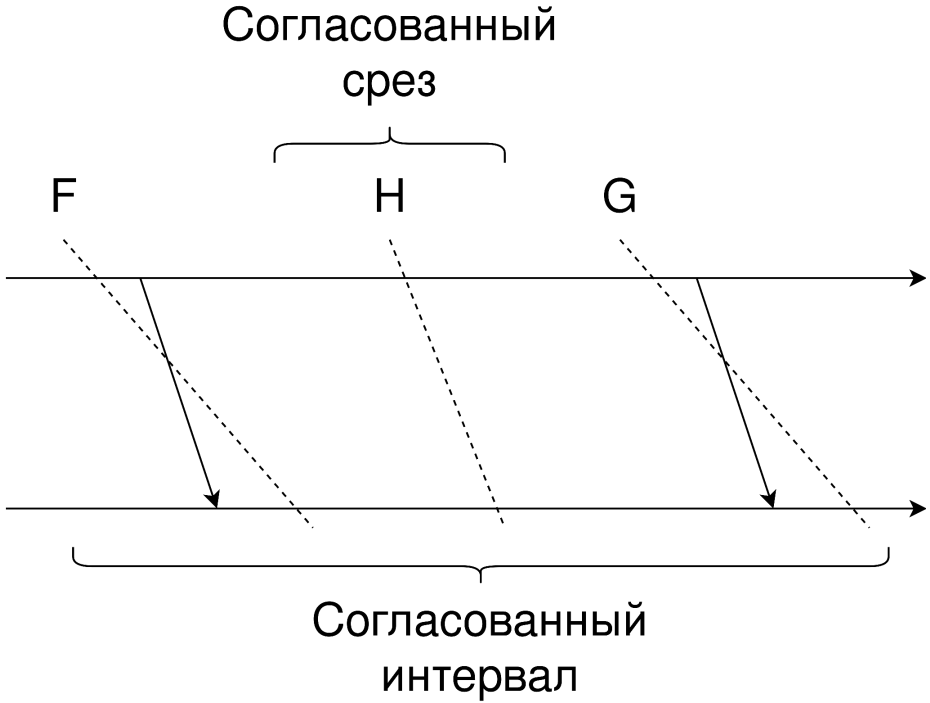

Согласованные интервалы

- Интервал [F, G] барьерно синхронизирован, если

$$\forall x \in F, y \in E \setminus G : x \to y$$

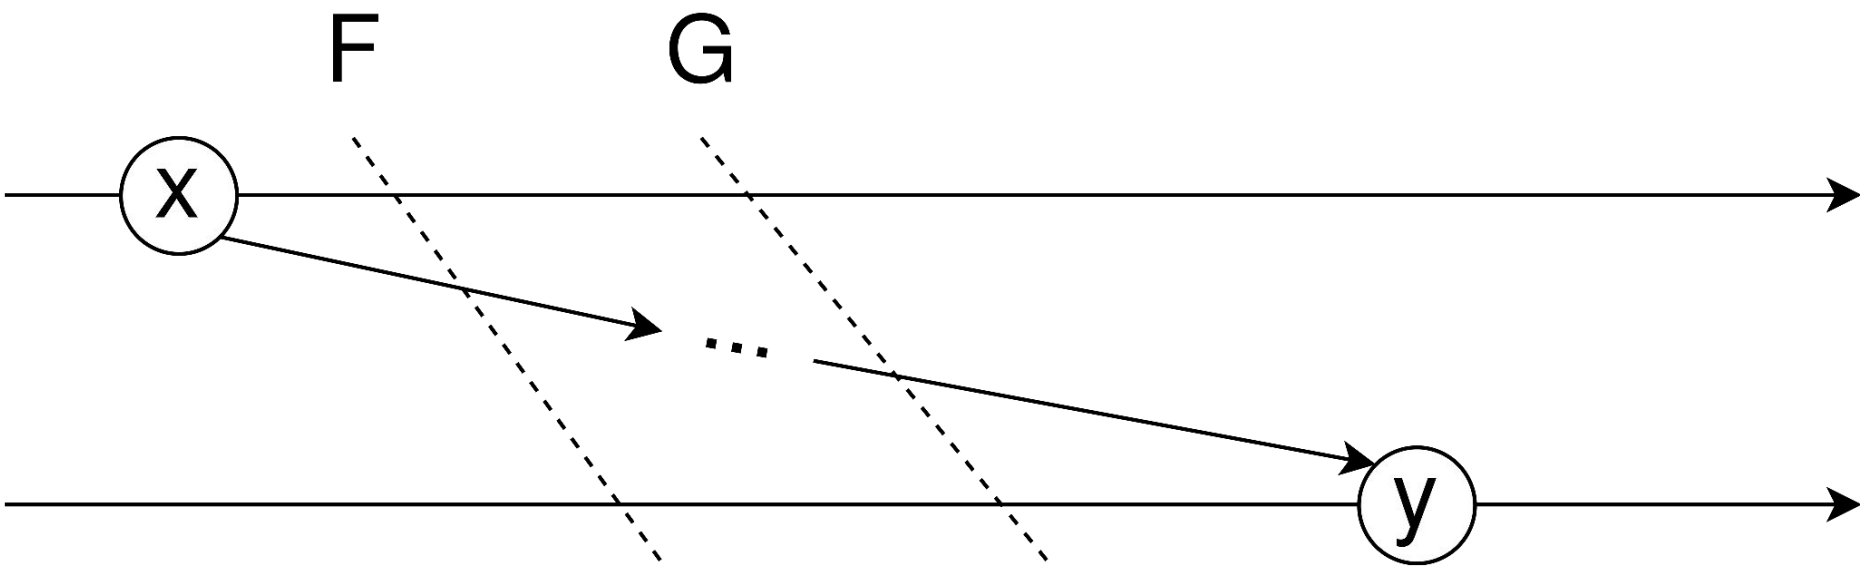

Согласованные интервалы

- Любой барьерно синхронизированный интервал согласован

$$(\forall x \in F, y \in E \setminus G : x \to y) \Rightarrow (\nexists y \in E \setminus G, x \in F : y \to x)$$

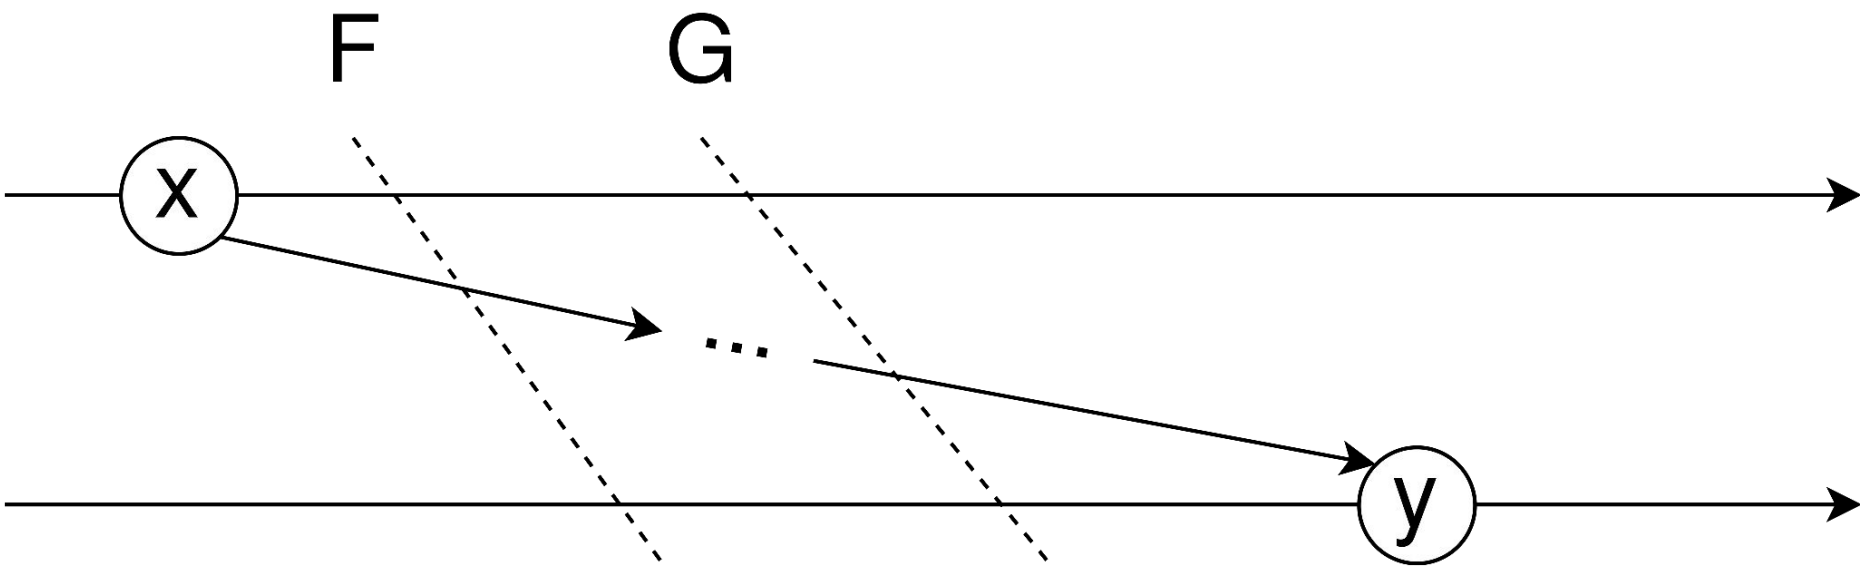

Согласованные интервалы

- Строим барьерно синхронизированный интервал через координатора
- 2 (N - 1) сообщение
- Может ли координатор отвечать сразу, не дожидаясь сообщений от всех?

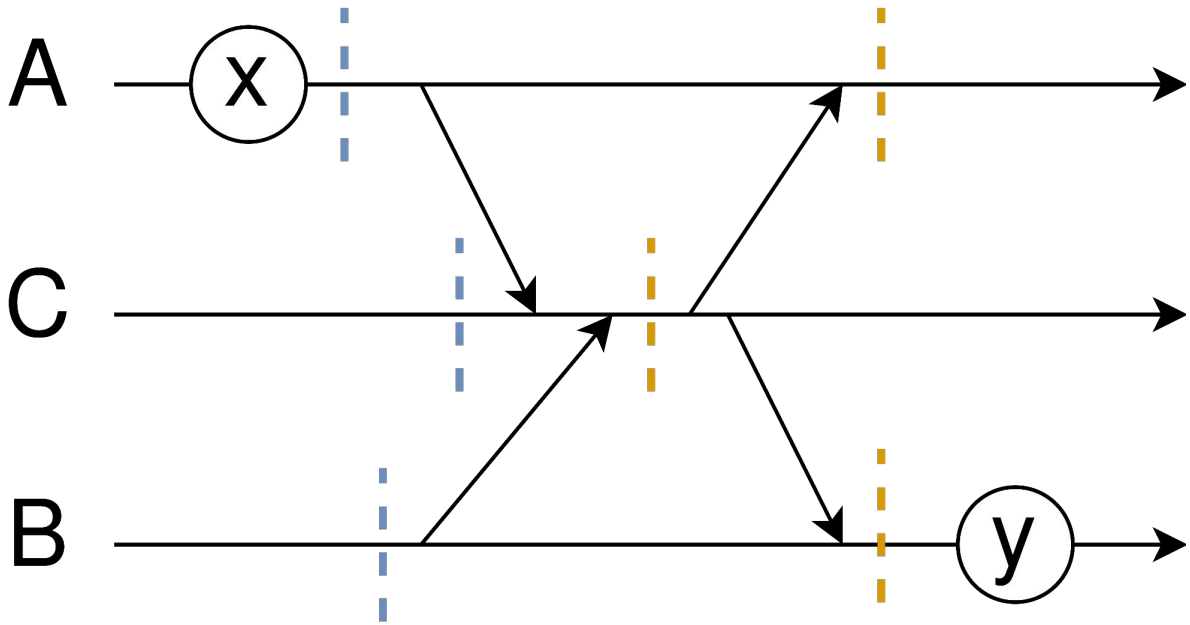

Согласованные интервалы

- Посылаем токен по кругу два раза
- 2 (N - 1) сообщение

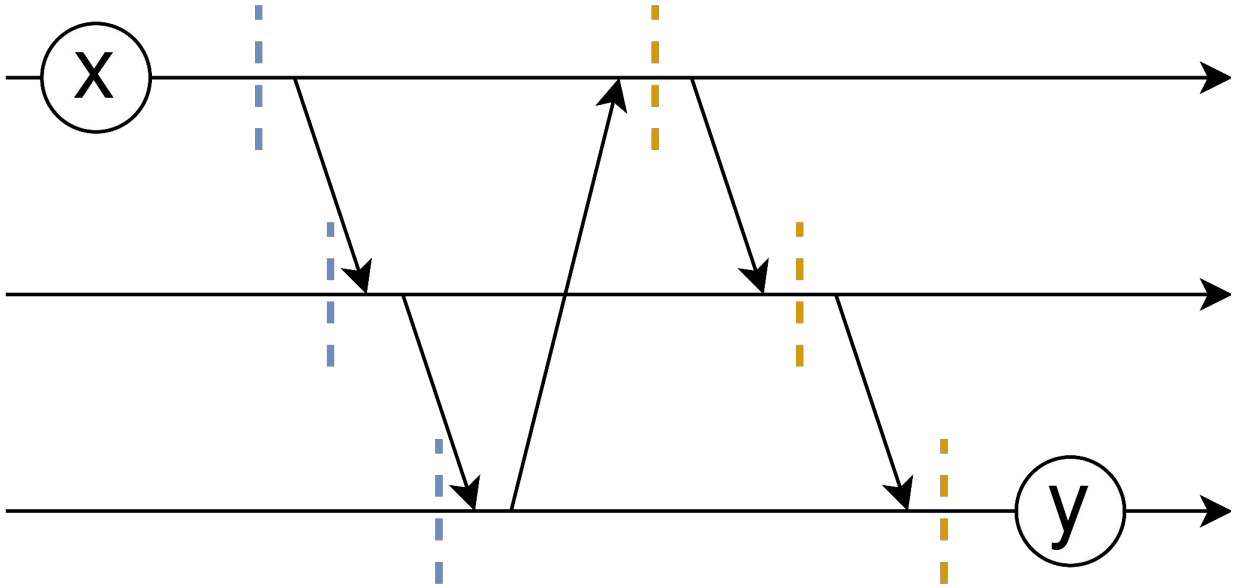

Локально стабильные предикаты

- Став однажды истинным, остаётся истинным всегда
- Определяется группой процессов, состояние которых не меняется
- Дедлок
- Окончание вычисления

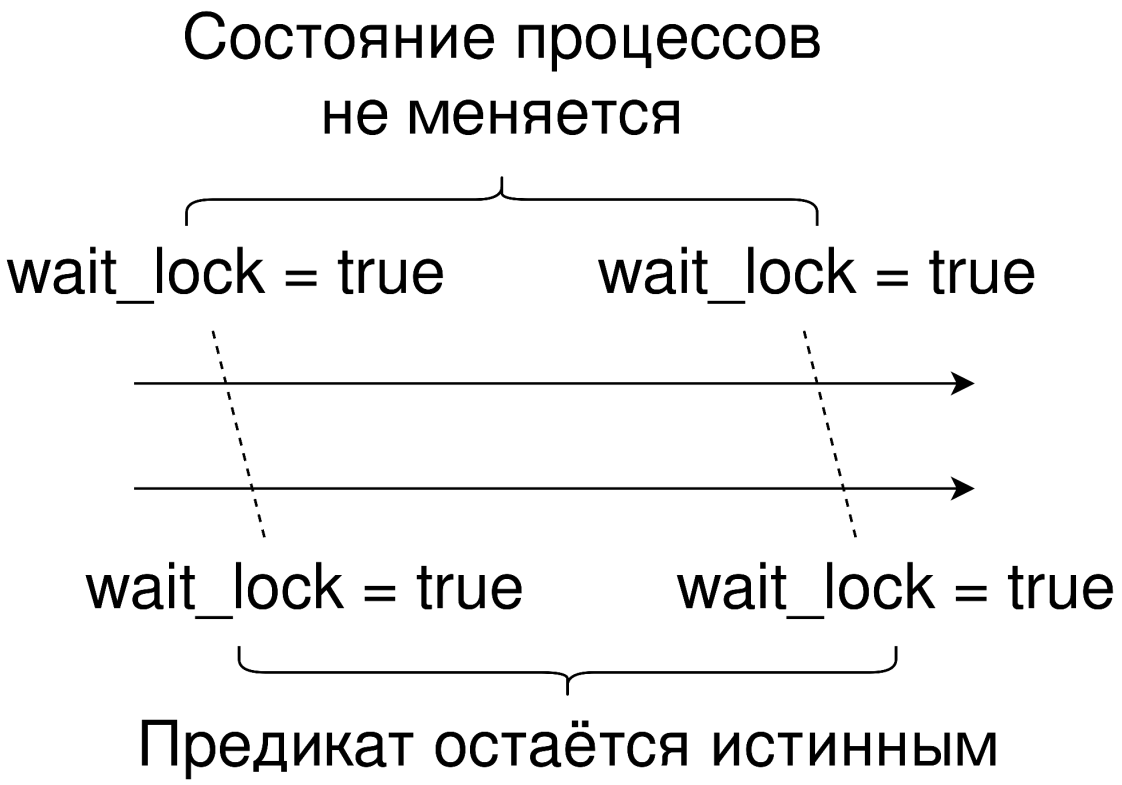

Локально стабильные предикаты

- Наличие в системе токена это не локально стабильный предикат

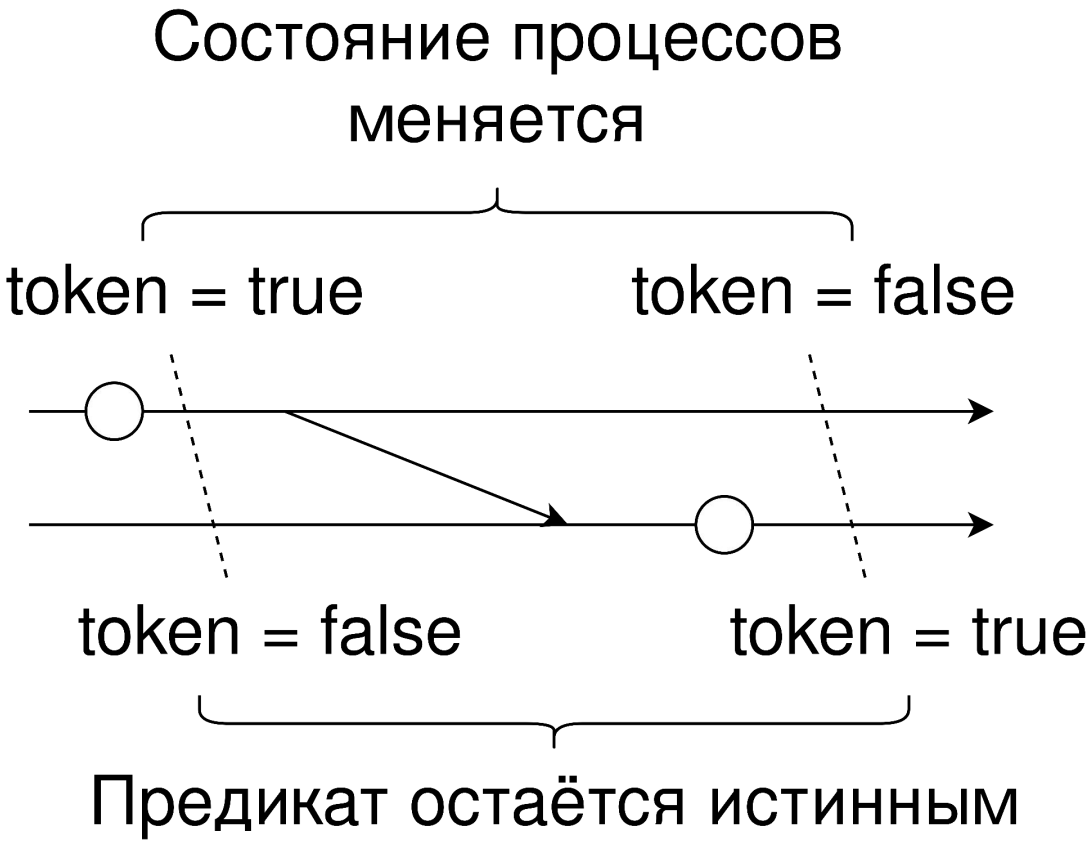

Локально стабильные предикаты

- Строим согласованный интервал за O(N) сообщений
- Если на F предикат выполнен
- И состояние не менялось до G
- То предикат выполнен на H

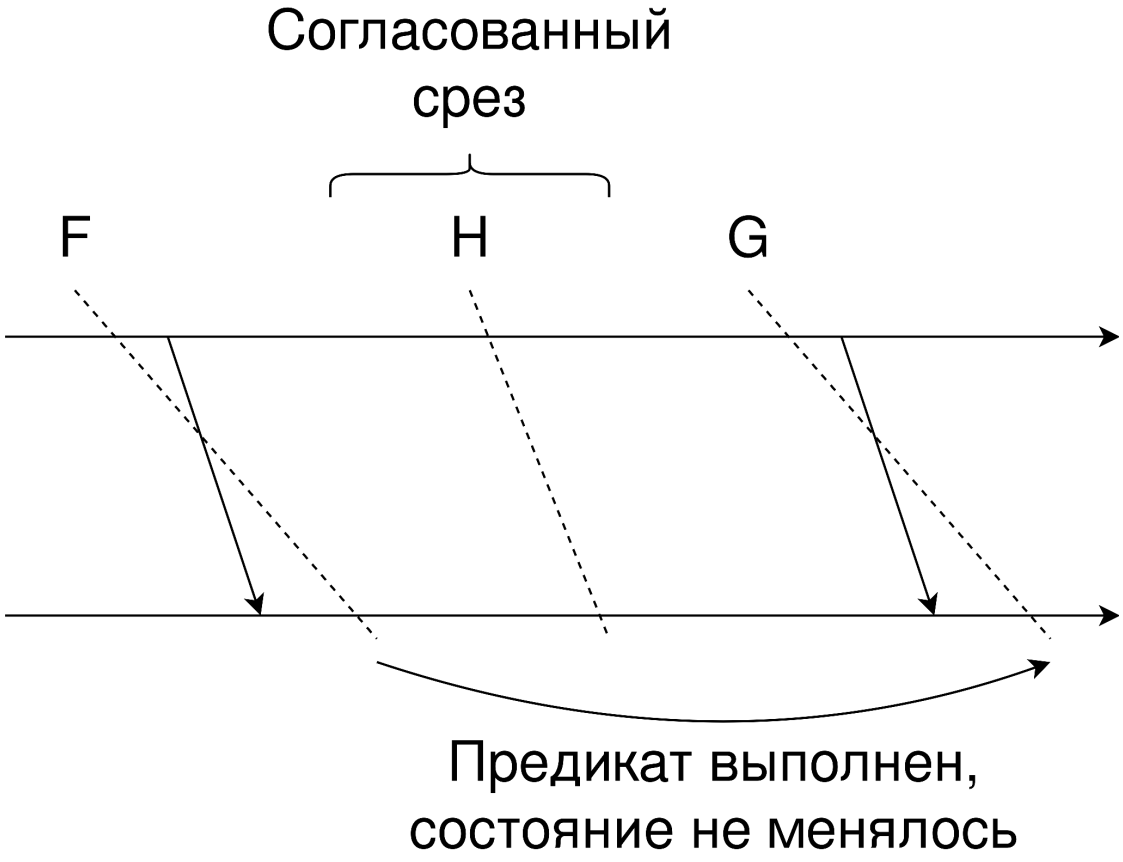

Что почитать:

- *Chandy K. M., Lamport L.* Distributed snapshots: Determining global states of distributed systems
- *Dijkstra E. W., Scholten C. S.* Termination detection for diffusing computations
- *Atreya R. et al.* Efficient detection of a locally stable predicate in a distributed system
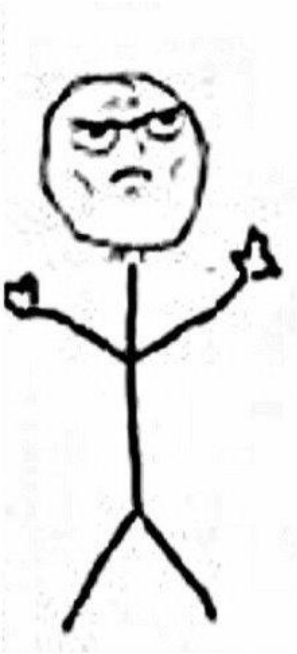
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание