Шардирование

Илья Кокорин

kokorin.ilya.1998@gmail.com

В предыдущих сериях

- Replicated State Machines (RSM)
  - Все узлы системы хранят копию одних и тех же данных
  - Синхронизируем реплики с помощью консенсуса
- Но зачем?

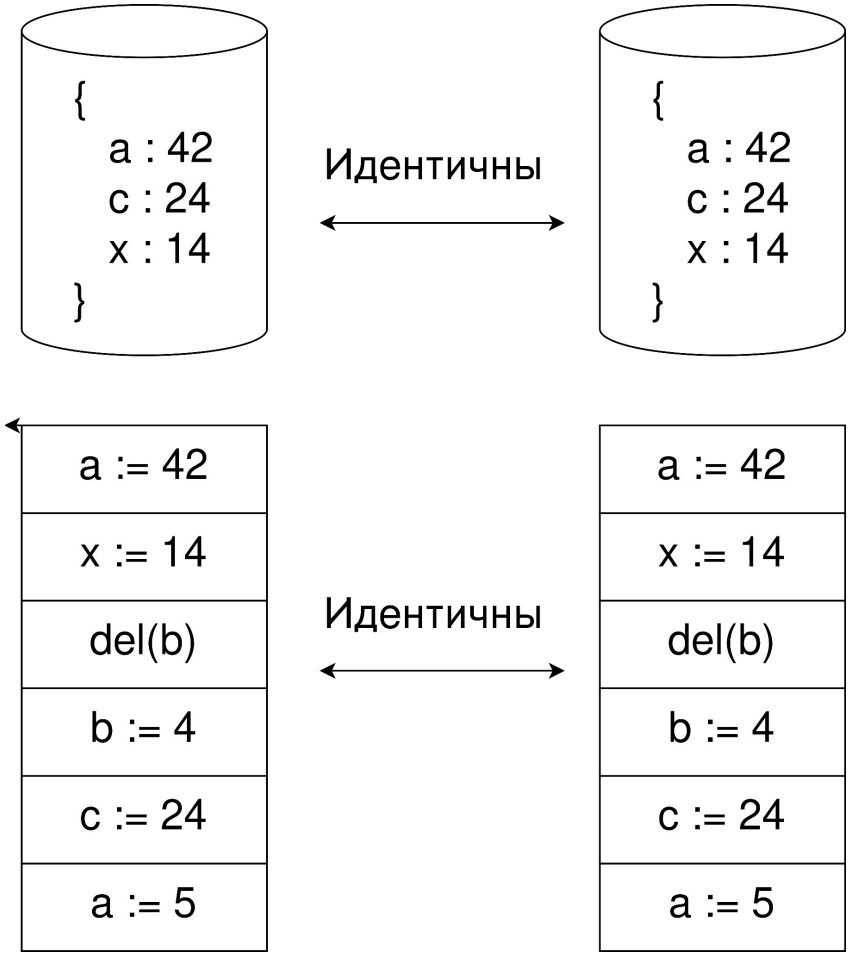

Шардирование: мотивация

- Храним данных больше, чем доступно памяти на одном узле
- Каждый узел обслуживает запросы только к тем данным, которые он хранит
- Не обслуживает запросы к чужим данным
- Больше запросов в секунду

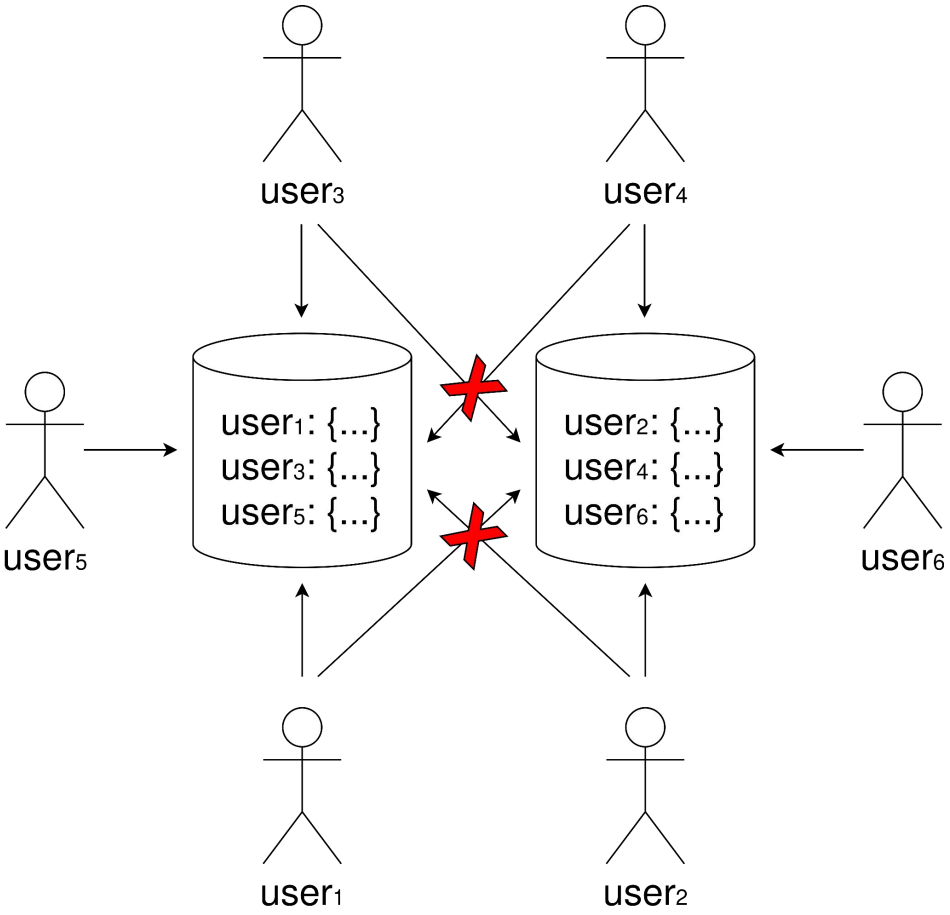

Шардирование по модулю

- `node_id := hash(key) % p`
- Узлы заполнены равномерно
- При добавлении/удалении узла приходится перемещать Θ(N) ключей
  - 15 % 2 = 1
  - 15 % 3 = 0
- Перемещаем ключи между существующими узлами

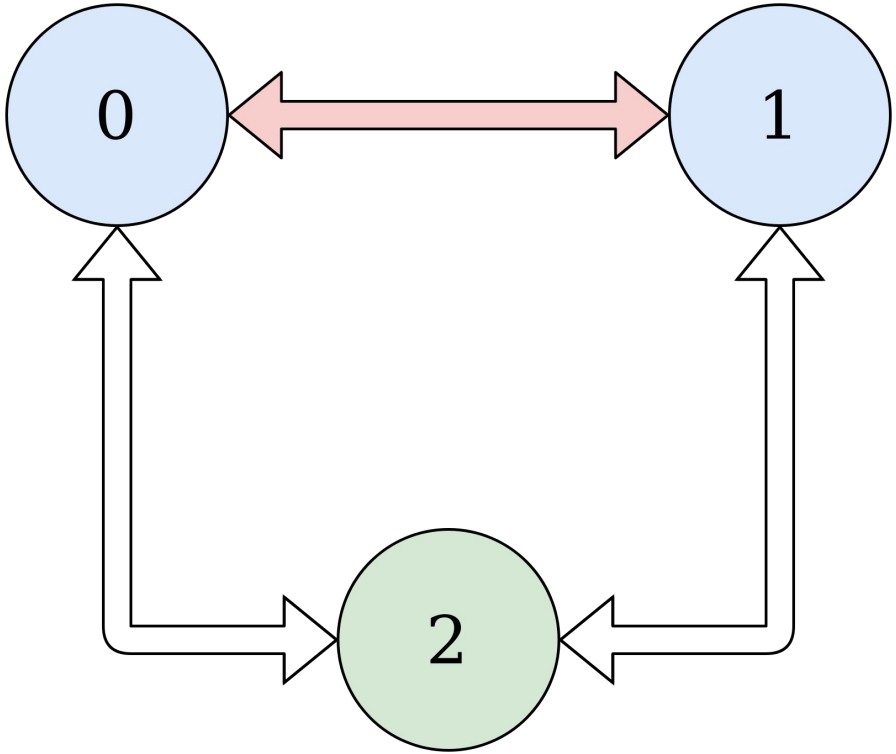

Шардирование по модулю: расширение

- Можем расширить кластер в два раза
- Для каждого сервера покупаем ещё один
- Переносим половину ключей на новый сервер

Шардирование по модулю: расширение

- Пусть `hash(key) % p = k`
  - Рассмотрим k-ый сервер
- Значит, `hash(key) % 2p = k`
  - Эти ключи оставляем на k-ом сервере
- Или `hash(key) % 2p = k + p`
  - Переносим на парный сервер
- Можно удалить половину кластера обратной операцией

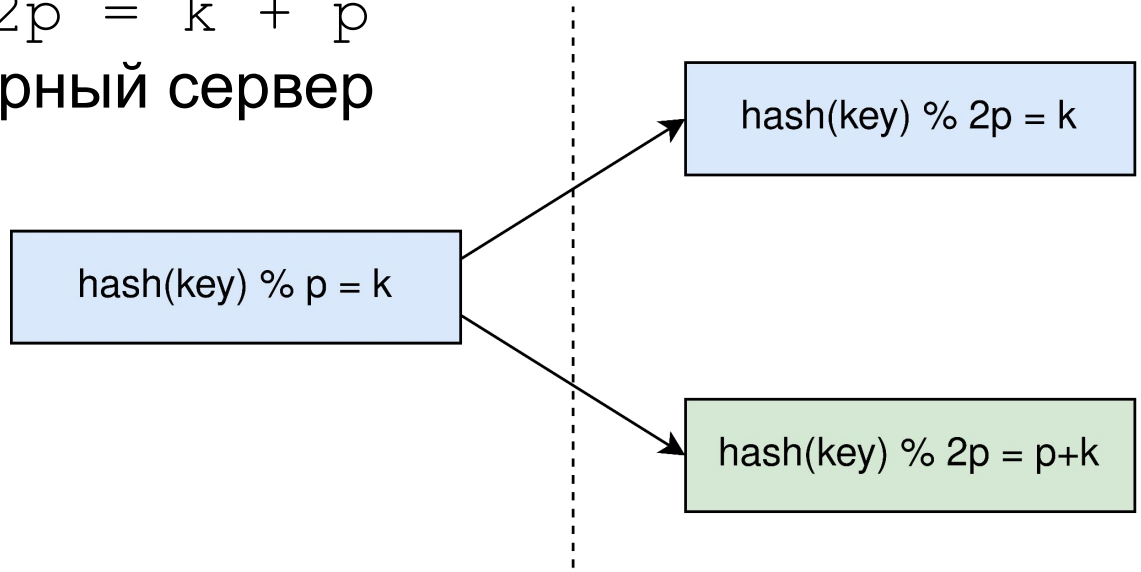

Шардирование по модулю: расширение

- Можно расширять в любое натуральное число раз

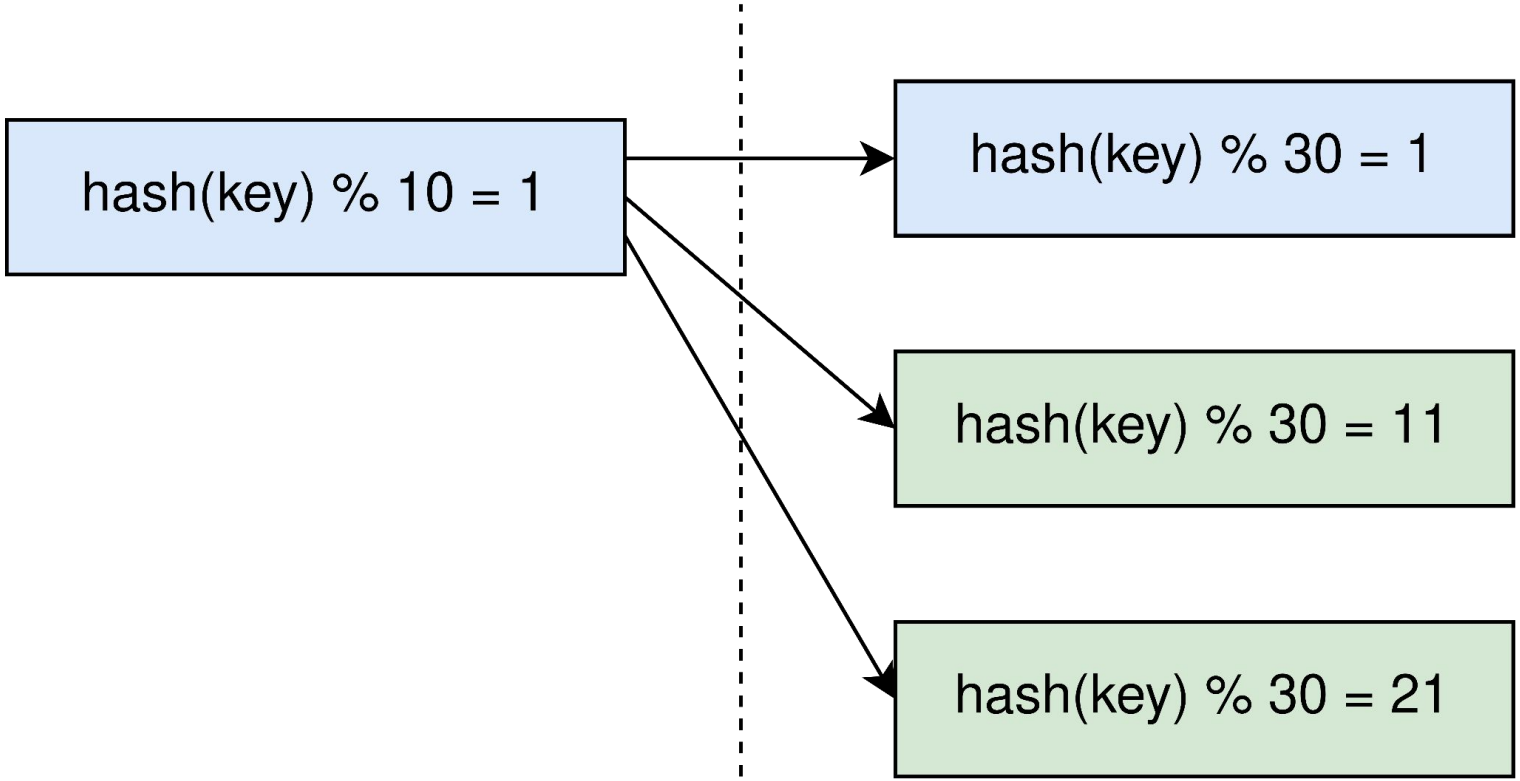

Битовый бор

- Берём битовое представление хеша и спускаемся по дереву
- Лист — сервер, хранящий ключ

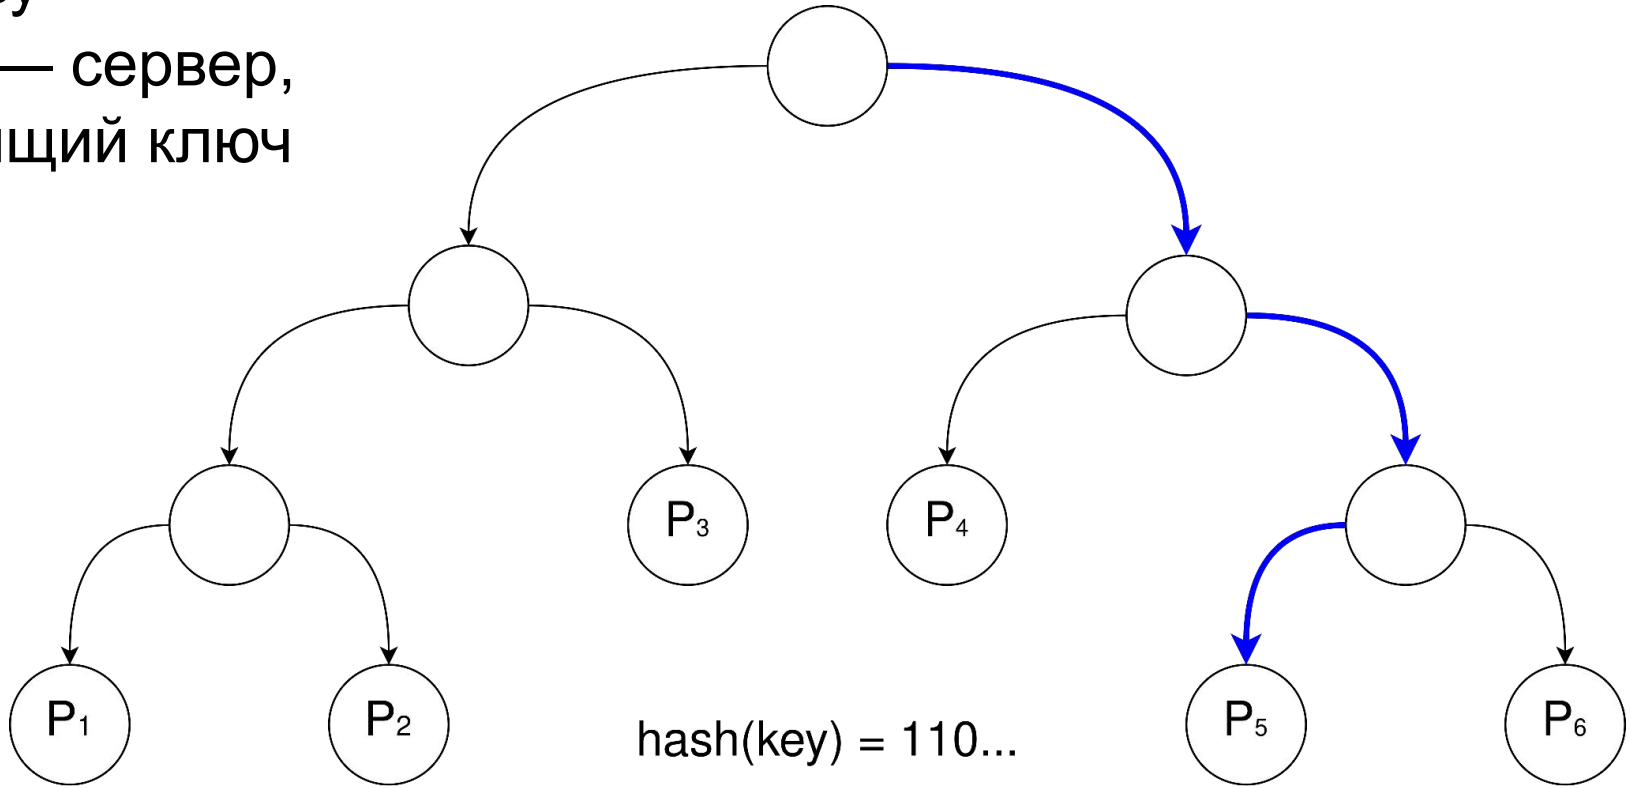

Битовый бор: расширение

- Расщепляем вершину на две
- Переносим примерно половину ключей на новый сервер
- Определяем по i-ому биту хеша
- Из одного заполненного сервера получаем два заполненных наполовину

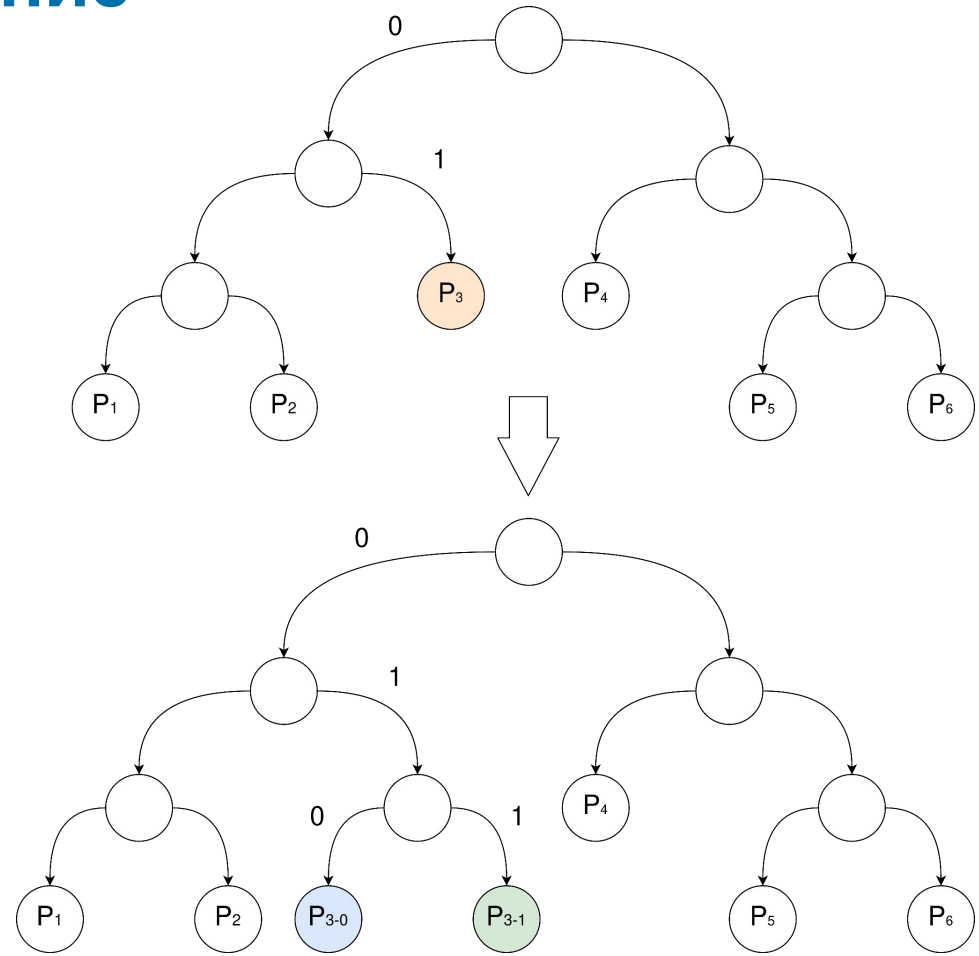

Битовый бор: удаление

- Если у удаляемой вершины есть брат-лист, переносим все ключи на него
- Из двух наполовину заполненных серверов получаем один заполненный целиком

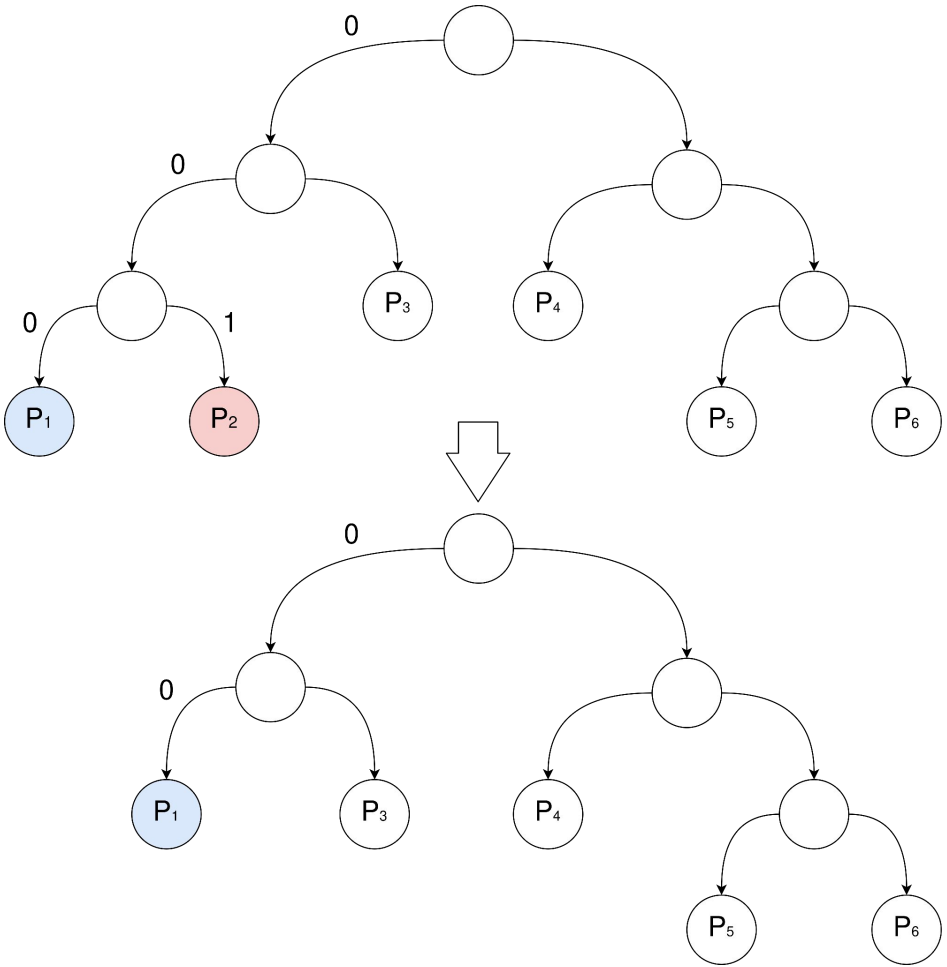

Битовый бор: удаление

- Если у удаляемой вершины нет брата-листа, можем заменить только целое родительское поддерево на один лист
- Приходится удалять и другие листья

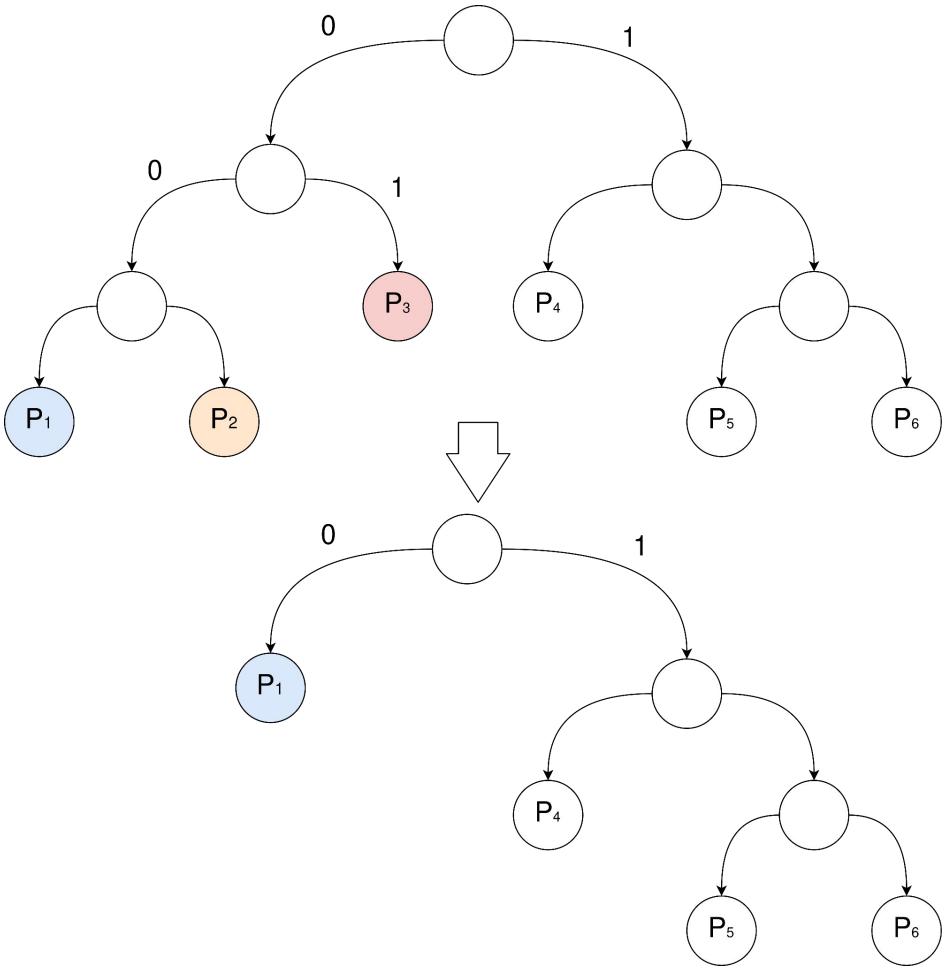

Постоянное число секций

- Заводим N секций
- Ключи по секциям распределяем тривиально
- Секции храним на серверах

- Централизованно храним информацию о том, какая секция где хранится

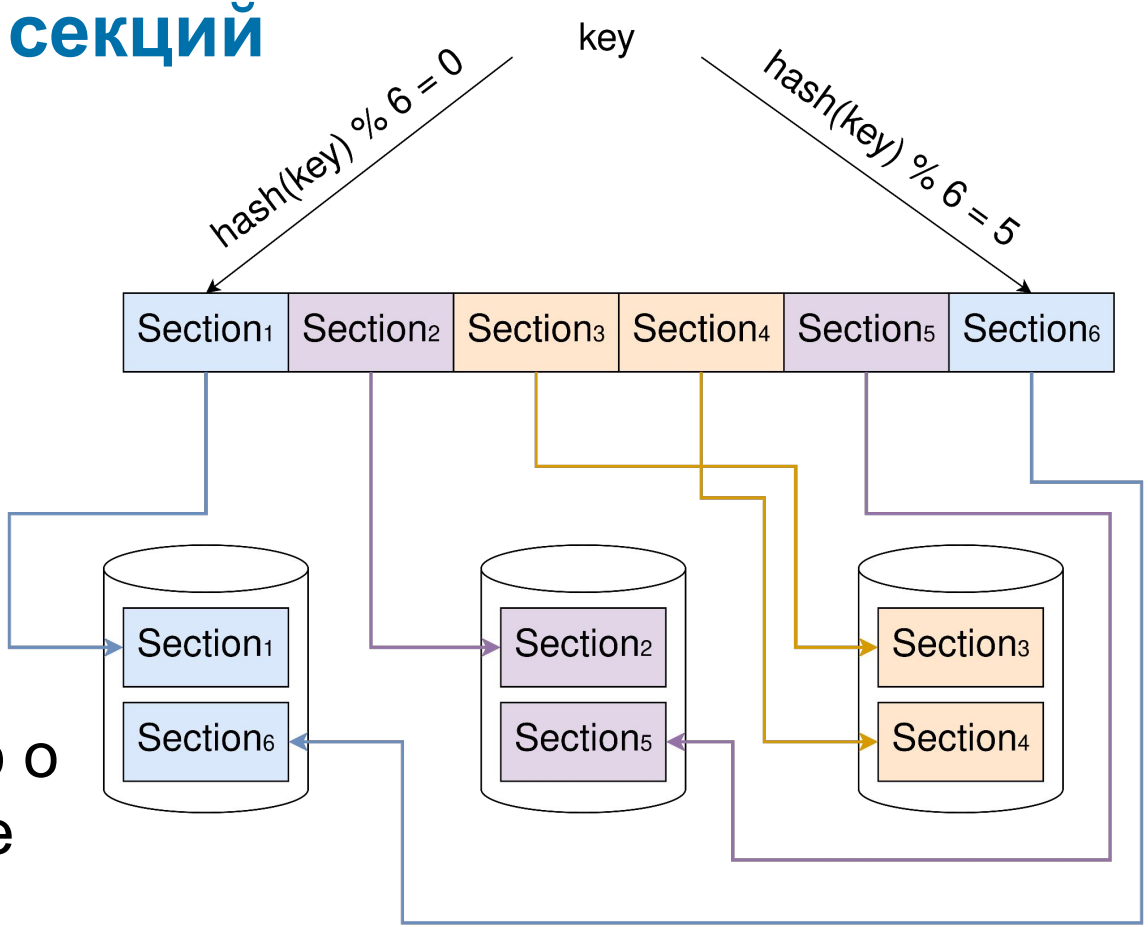

Добавление сервера

- Переносим часть секций на новый сервер

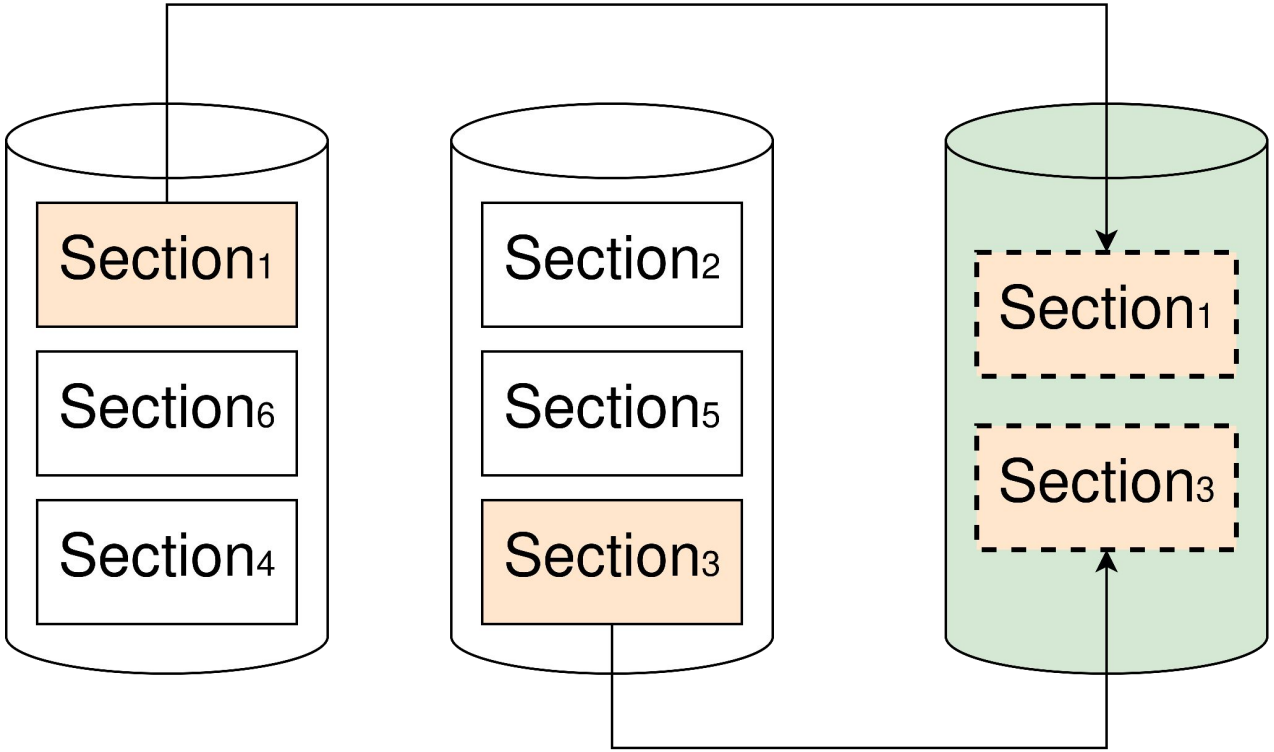

Удаление сервера

- Переносим секции с удаляемого сервера на оставшиеся

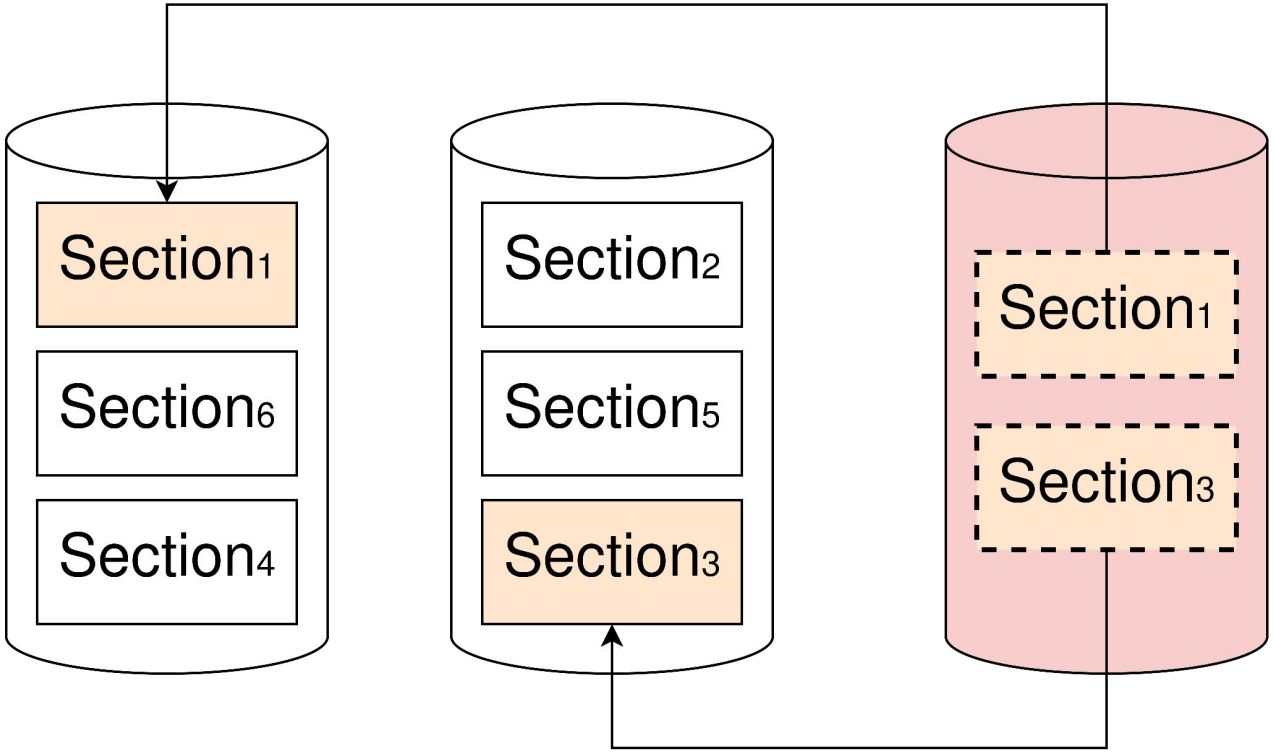

Выбор числа секций

- Нельзя слишком мало
- Иначе на очередному серверу не достанется секции

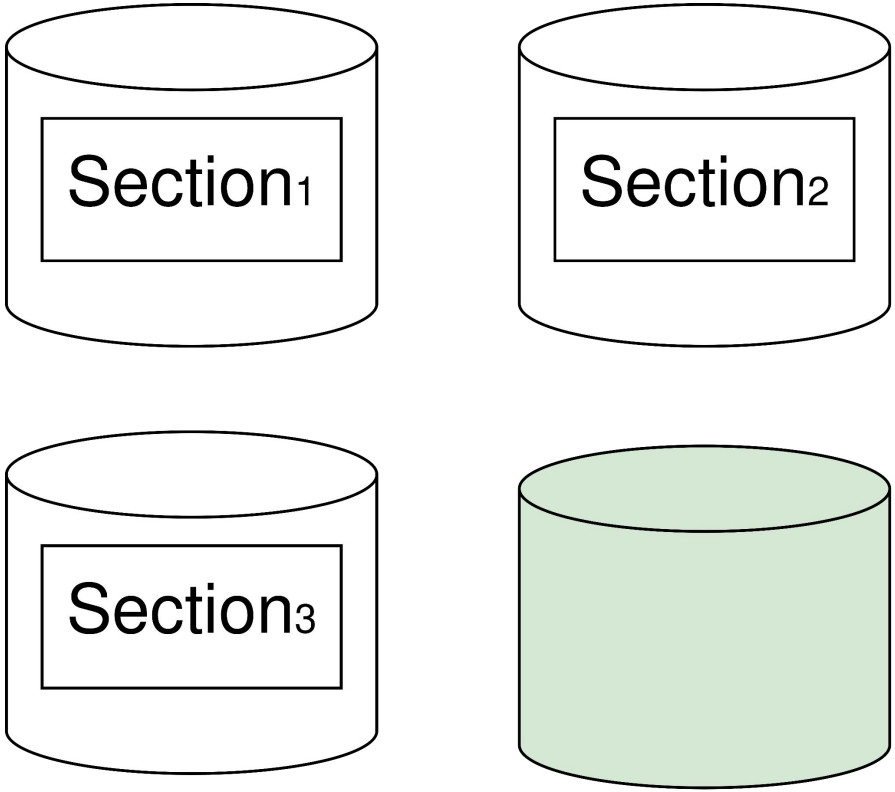

Выбор числа секций

- Чем больше секций, тем больше возможностей для балансировки
- Меньше секций на нагруженные сервера, больше на разгруженные

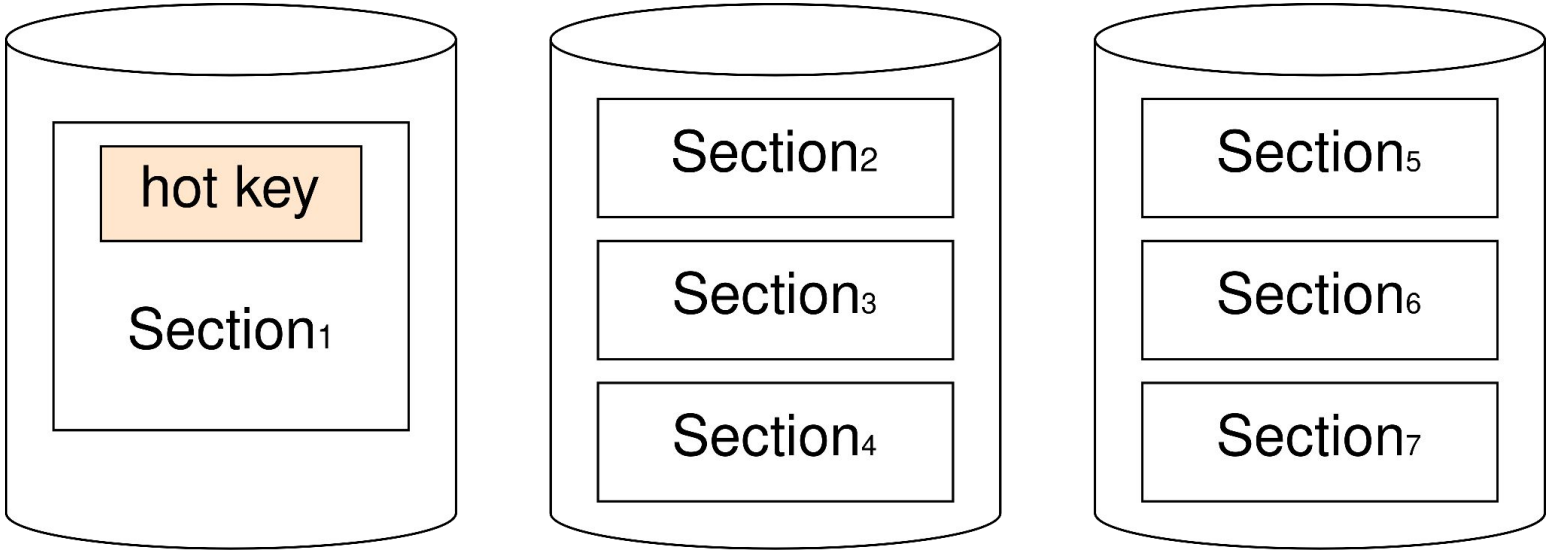

Многоуровневое шардирование

- Нужно хранить информацию вида `section → server`
- Её тоже можно шардировать
- Её меньше, чем исходной информации
- Для хранения нужно меньше серверов

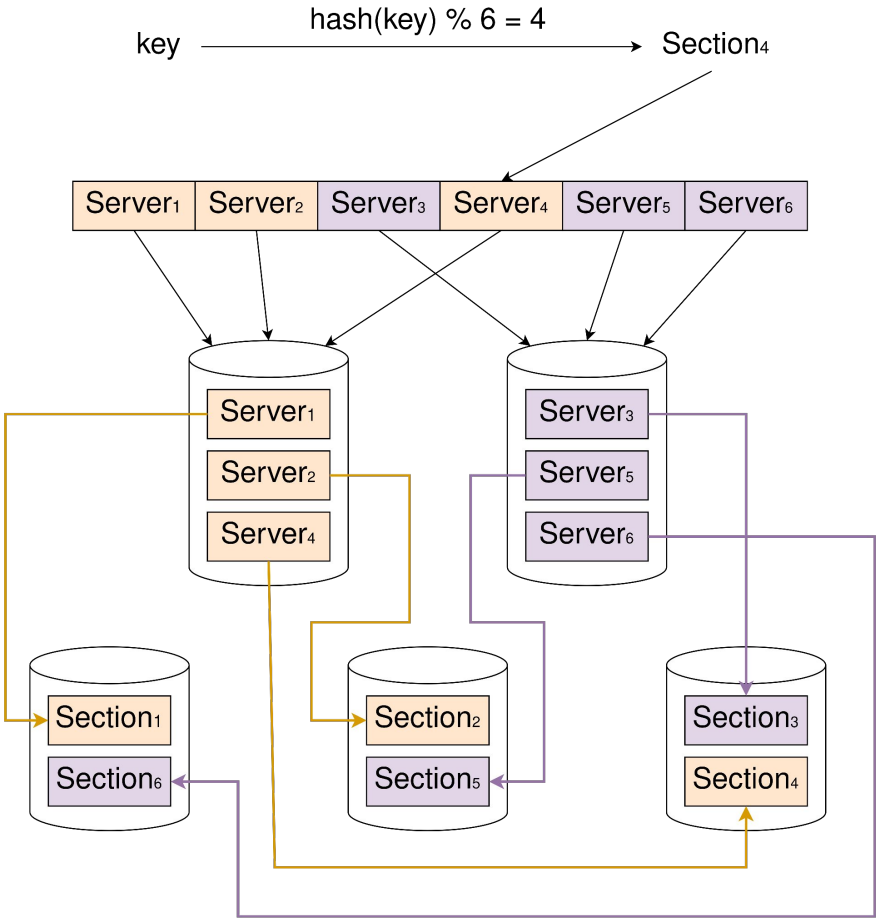

Rendezvous hashing

- `node_id = argmax hash(key || i)`
  `i= 1 to P`
- Равномерное распределение ключей
  - Если хеш-функция “хорошая”
- При добавлении узла каждый существующий узел перемещает только те ключи, которые должны перейти на новый узел
  - `hash(key || new_id) > hash(key || cur_id)`
- При удалении узла перемещаются только те ключи, которые располагались на этом узле
- Поиск узла по ключу за O(K)

Консистентное хеширование

- Каждому узлу соответствует точка на круге
  - hash(node_name)
- Проецируем ключ на круг
  - hash(key)
- Ищем следующую по часовой стрелке точку, соответствующую узлу

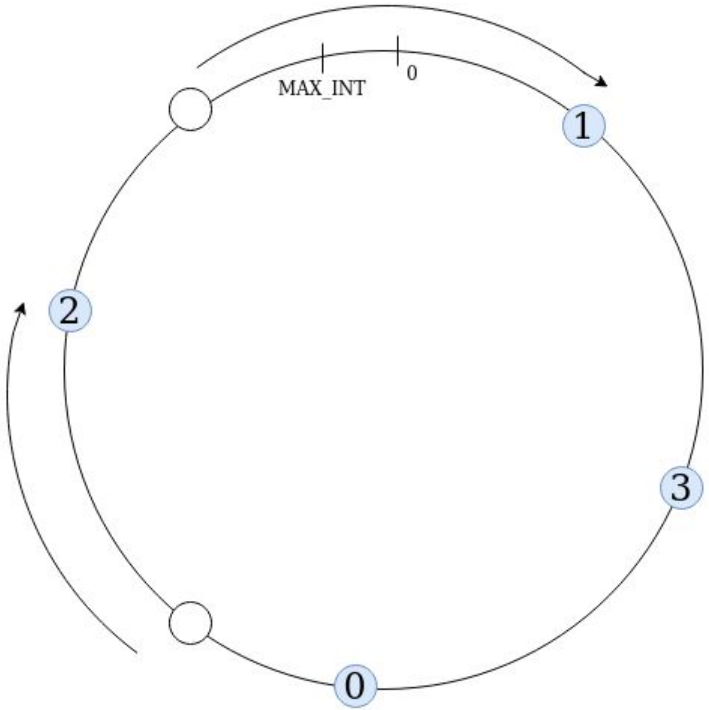

Консистентное хеширование: добавление узла

- Проецируем новый узел на круг
- Ищем предыдущий и следующий по кругу узлы
- Перемещаем часть ключей со следующего по кругу узла на новый узел
- Ключи перемещаются только на новый узел

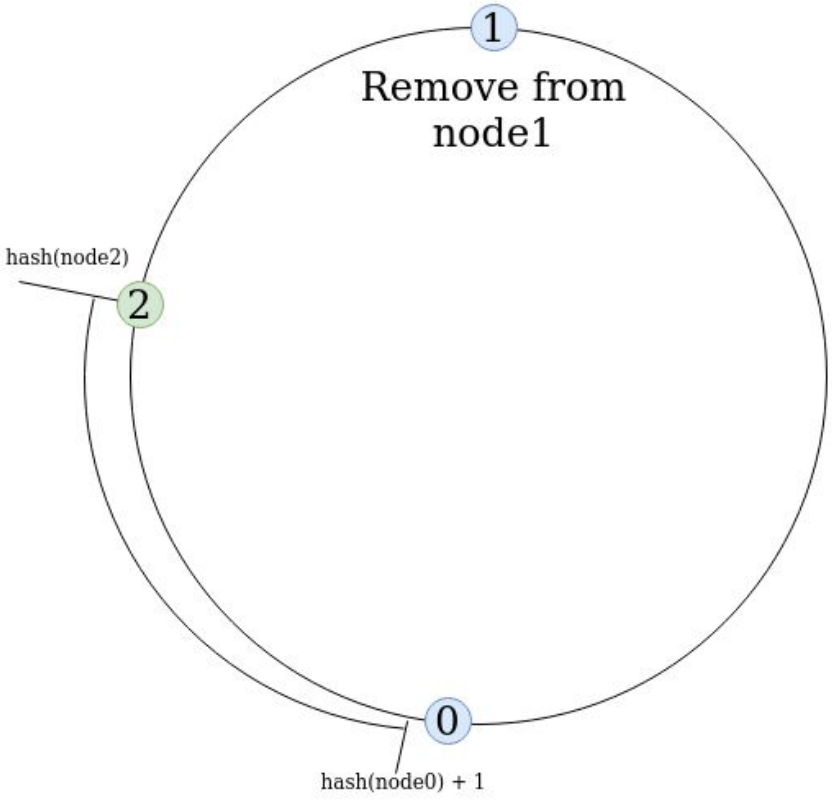

Консистентное хеширование: удаление узла

- Аналогично добавлению
- Ключи перемещаются только с удаляемого узла

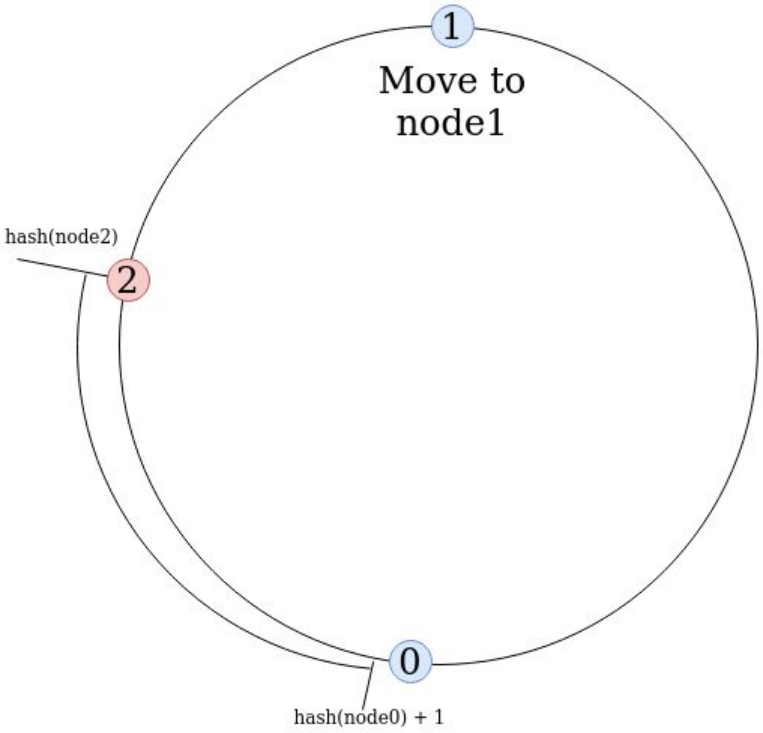

Хранение списка узлов

- В дереве поиска
  - O(log K) на поиск узла по ключу
  - O(log K) на добавление/удаление узла
- В сортированном массиве
  - O(log K) на поиск узла по ключу
  - O(K) на добавление/удаление узла

Перемещение ключей

- Перемещаются только непрерывные отрезки хешей вида `[hash(prev_node) + 1; hash(cur_node)]`
- Чтобы делать это быстро - храним на каждом узле `TreeMap<Hash, List<Key>>`

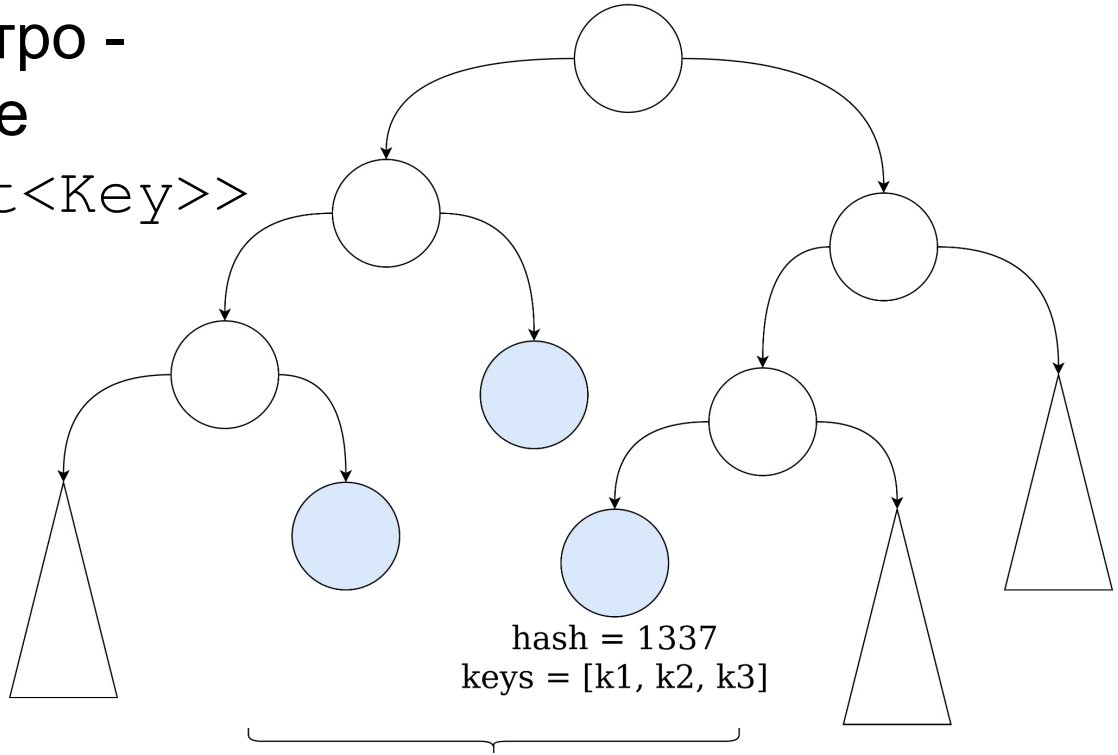

Неравномерное распределение ключей

- Такое возможно, так как отображения узлов на круг выбираются случайно
- При добавлении нового узла все свои ключи он забирает у единственного существующего узла
- При удалении узла мы перемещаем все его ключи на единственный узел

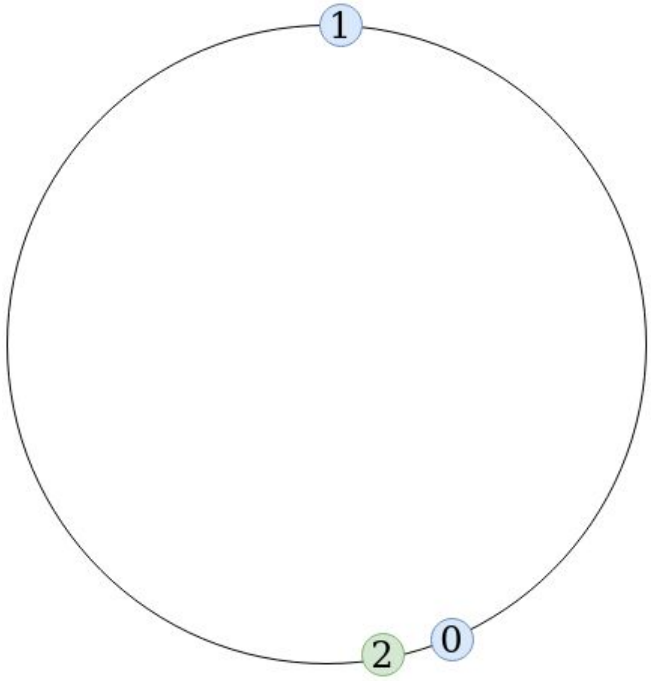

Консистентное хеширование: vnodes

- Каждому физическому узлу соответствует несколько виртуальных
  - `hash(node_name || 0), hash(node_name || 1), ...`
  - Чем больше - тем равномернее распределение
  - И больше нагрузка на память и время

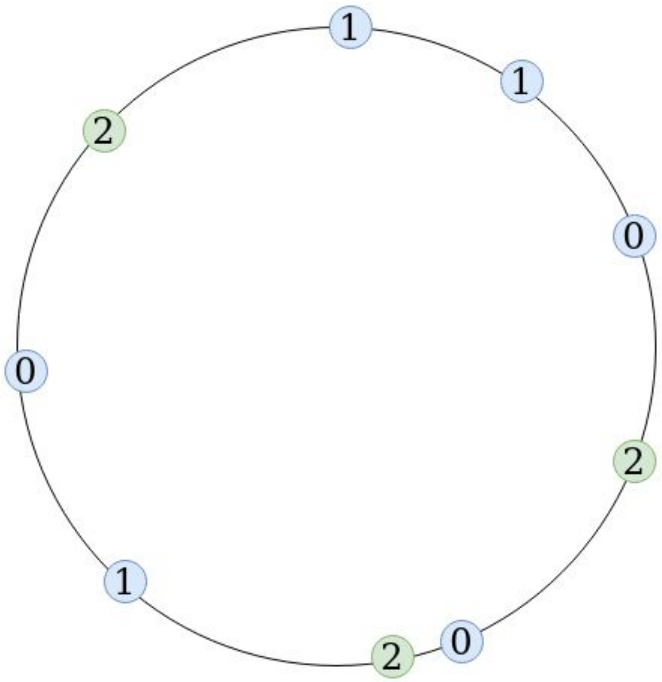

- Учитываем “вес” узла: чем больше vnodes, тем больше ключей

vnodes и равномерность распределение

- Фиксируем количество узлов
- Меняем количество vnode
- Генерируем случайные ключи
- Для каждого узла считаем, сколько ключей попало на этот узел

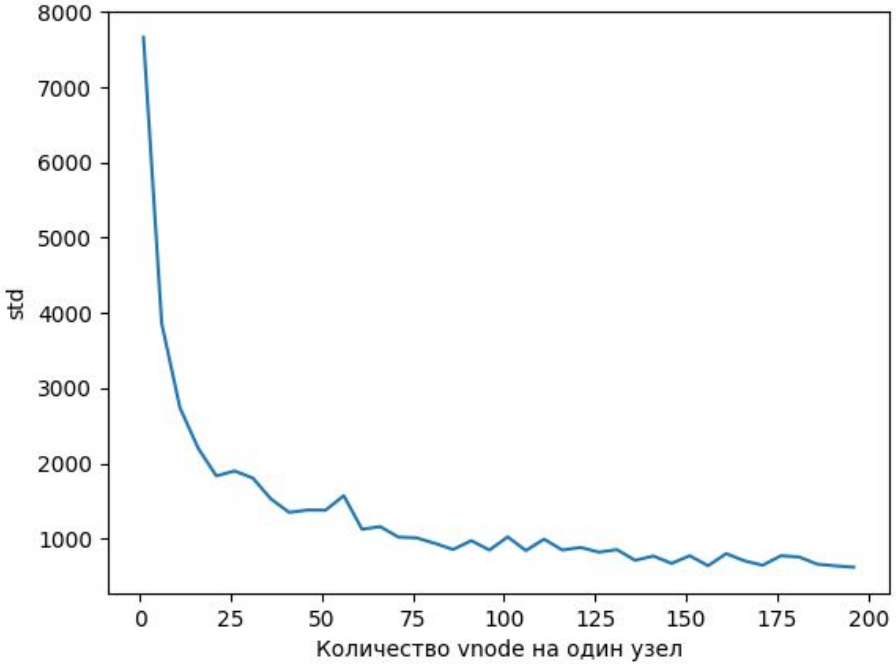

- Считаем стандартное отклонение (чем меньше - тем лучше) с усреднением по нескольким запускам

JumpHash

- Пусть `ch(key, n)` — индекс узла, хранящего ключ `key`
  - `0 ≤ ch(key, n) < n`
- `ch(key, 1) = 0` для всех ключей
- Переход от K серверов к K + 1:
  - Каждый ключ с вероятностью $\frac{1}{K+1}$ переходит на сервер с индексом K (новый узел)
- Сервера не удаляются, только добавляются новые
  - Количество данных в системе только растёт
  - При выходе сервера из строя мы не удаляем его из кластера, а заменяем его другим сервером с тем же индексом и теми же данными

JumpHash: доказательство равномерности распределения

$0 \leq \xi_n < n$

Докажем, что $P\left(\xi_n = i\right)|_{0 \leq i < n} = \frac{1}{n}$

База: $P(\xi_1 = 0) = 1$

Переход: покажем, что

$P\left(\xi_n = i\right)|_{0 \leq i < n} = \frac{1}{n} \Rightarrow P\left(\xi_{n+1} = i\right)|_{0 \leq i < n+1} = \frac{1}{n+1}$

- $i = n : P\left(\xi_{n+1} = n\right) = \sum_{i=0}^{n-1} P\left(\xi_n = i\right) \cdot \frac{1}{n+1} = \sum_{i=0}^{n-1} \frac{1}{n} \cdot \frac{1}{n+1} = \frac{1}{n+1}$
- $i \neq n : P\left(\xi_{n+1} = i\right) = P\left(\xi_n = i\right) \cdot \left(1 - \frac{1}{n+1}\right) = \frac{1}{n} \cdot \frac{n}{n+1} = \frac{1}{n+1}$

Монета с заданным распределением

С вероятностью $p \in (0;1)$ выпадает орёл, с вероятностью $1-p$ выпадает решка

$$r \sim U(0;1)$$

$$P(r < p) = \int_0^p f_{U(0;1)}(x)dx = \int_0^p dx = p$$

JumpHash: наивная реализация

- N раз эмулируем процесс добавления нового сервера
- Подкидываем монетку и смотрим, нужно ли перемещать ключ

```
1 fun jump_hash(key: Key, n: Int) -> Int:
2     random.set_seed(hash(key))
3     result = 0
4     for i = 1; i < n; i += 1:
5         if random.uniform(0, 1) < 1/(i+1):
6             result = i
7     return result
```

- Используем псевдослучайные числа, seed инициализируем хешом ключа
  - Всегда получаем один и тот же результат для ключа key

JumpHash: оптимизация

- `ch(key, n) = ch(key, n + 1)` в большинстве случаев
- Заметим, что в большинстве случаев
- Прыжок происходят редко
- Прыжок происходит когда `ch(key, n + 1) = n + 1`

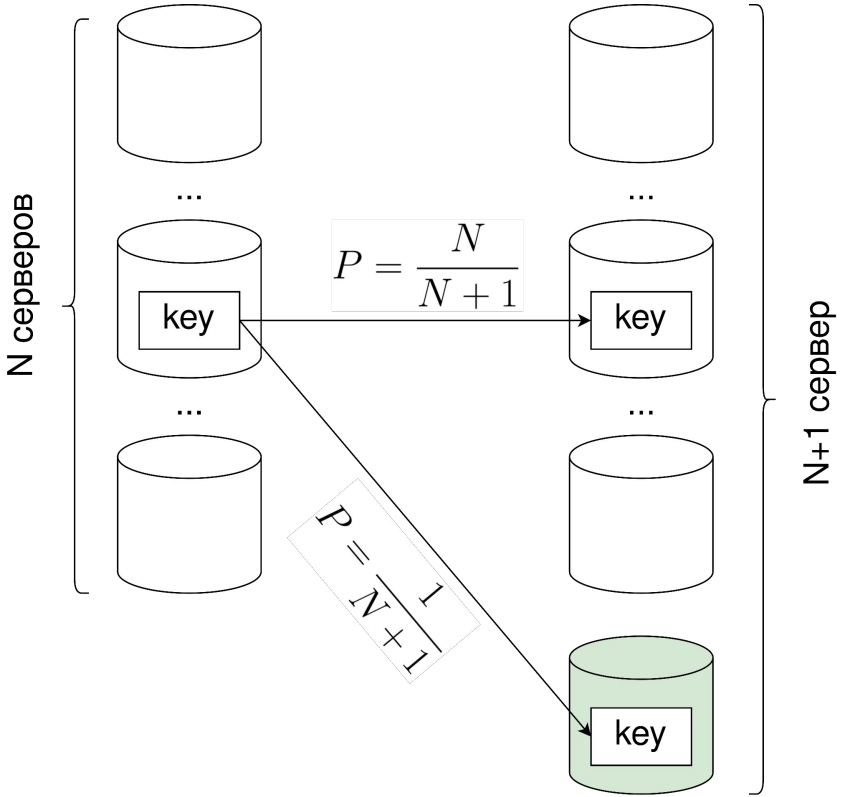

JumpHash: поиск точки следующего прыжка

- Пусть b - точка последнего прыжка
  - `ch(key, b) ≠ ch(key, b + 1)`
  - `ch(key, b + 1) = b`
- Найдём точку следующего прыжка
  - Такое максимальное `j`, что

    `ch(key, j) = ch(key, b + 1)`
- `j ≥ i (i ≥ b + 1)`, если в точке `i` не произошло прыжка
  - Если `ch(key, i) = ch(key, b + 1)`
- `P(j ≥ i) = P(ch(key, i) = ch(key, b + 1))`
- Посчитаем $P\left(ch(key, n) = ch(key, m)\right)\big|_{n \geq m}$

JumpHash: доказательство леммы

Докажем, что $P\left(ch(key, n) = ch(key, m)\right)|_{n \geq m} = \frac{m}{n}$

- $n = m : P\left(ch(key, n) = ch(key, m)\right) = 1$
- $n > m$: не должно произойти прыжков на

1. $m + 1$-ом шаге (вероятность этого $1 - \frac{1}{m+1} = \frac{m}{m+1}$)
2. $m + 2$-ом шаге (вероятность этого $1 - \frac{1}{m+2} = \frac{m+1}{m+2}$)
3. ...
4. n-ом шаге (вероятность этого $1 - \frac{1}{n} = \frac{n-1}{n}$)

Вероятность того, что ни одного из этих прыжков не будет, равна $\frac{m}{\cancel{m+1}} \cdot \frac{\cancel{m+1}}{\cancel{m+2}} \cdot \ldots \cdot \frac{\cancel{n-1}}{n} = \frac{m}{n}$

JumpHash: финишная прямая

$$P\left(j \geq i\right) = P\left(ch(key, i) = ch(key, b+1)\right) = \frac{b+1}{i}$$

Сгенерируем случайное число $r \sim U(0;1)$

$j \geq i$, т. и т.т. $r \leq \frac{b+1}{i} \Rightarrow j \geq i$, т. и т.т. $i \leq \frac{b+1}{r}$

i - нижняя граница на j, поэтому $j = max\{i : i \leq \frac{b+1}{r}\}$

$j = \lfloor \frac{b+1}{r} \rfloor$

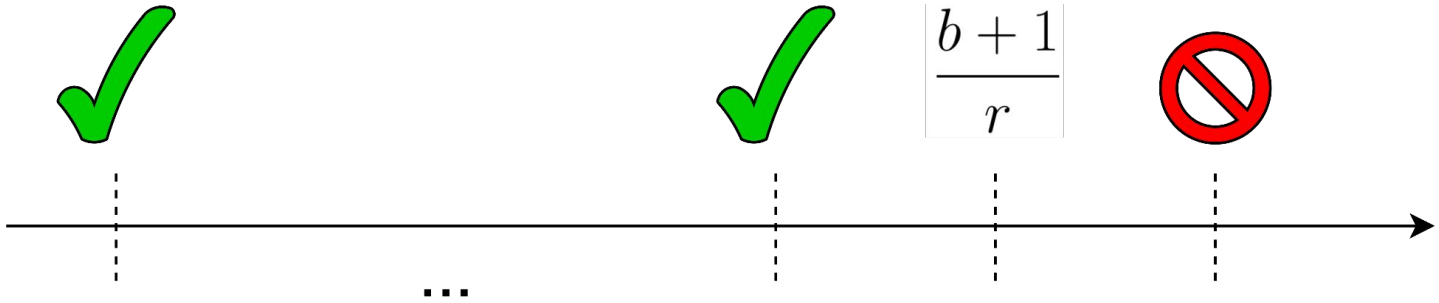

$i \leq \frac{b+1}{r} \Rightarrow j \geq i$

$i \leq \frac{b+1}{r} \Rightarrow j \geq i$

$i > \frac{b+1}{r} \Rightarrow j < i$

JumpHash: код алгоритма

```
fun jump_hash(key: Key, n: Int) -> Int:
    random.set_seed(hash(key))
    b = -1 # last jump point
    j = 0 # next jump point
    while j < n:
        b = j
        r = random.uniform(0, 1)
        j = ⌊(b+1)/r⌋
    return b
```

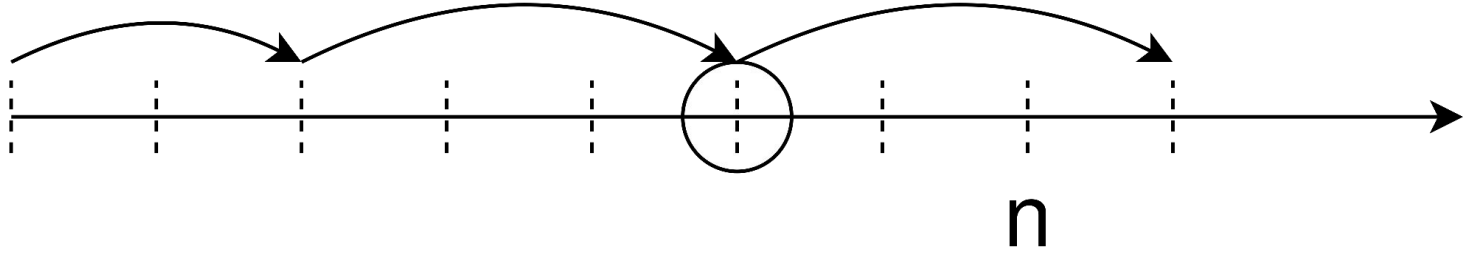

JumpHash: оценка времени работы

- Совершаем только прыжки вперёд
- На каждый узел прыгаем не более одного раза

$$\xi_i = \begin{cases} 1 & \text{если мы совершили прыжок на } i\text{-ый узел} \\ 0 & \text{иначе} \end{cases}$$

$$\mathbb{E}\,\xi_i = P\,(\text{мы совершили прыжок на } i\text{-ый узел}) = \frac{1}{i}$$

Оценим математическое ожидание времени работы:

$$\mathbb{E}\,T(n) = \sum_{i=1}^{n-1} \mathbb{E}\,\xi_i = \sum_{i=1}^{n-1} \frac{1}{i} = O(\log n)$$

JumpHash: добавление серверов

- Сервер проходится по всем своим ключам
- Вычисляет
  `ch(key, n + 1)`
- Перемещает, если
  `ch(key, n + 1) = n + 1`

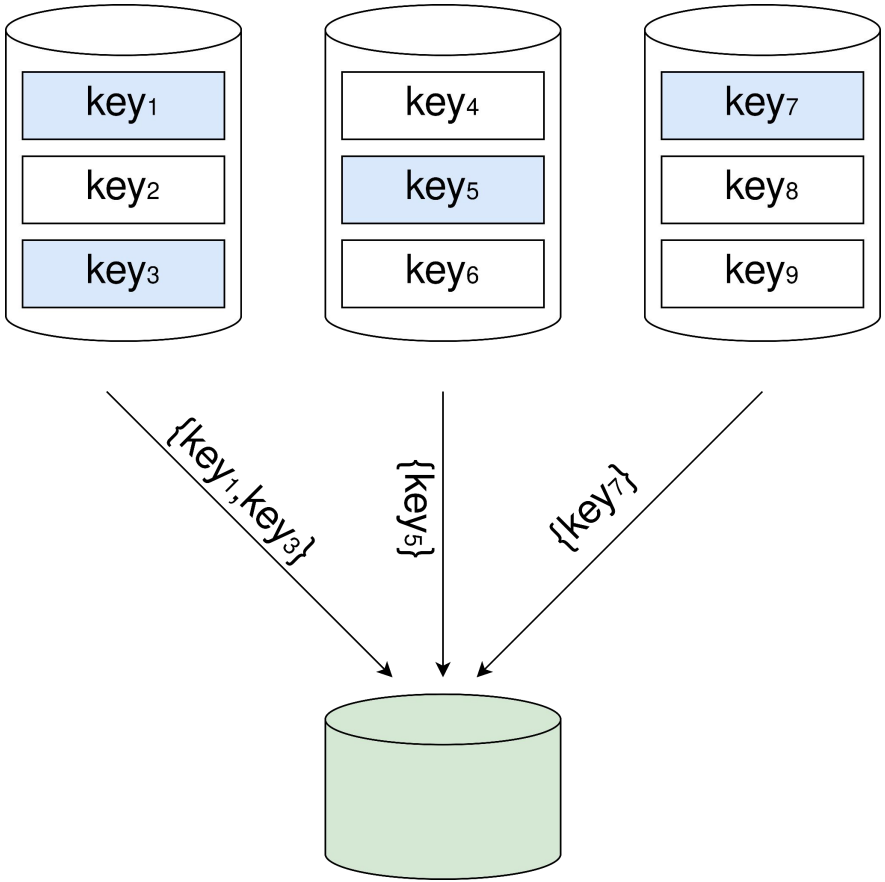

JumpHash: заключение

- Использует O(1) памяти, не использует память на хранение списка vnode
- Очень хорошо распределяет нагрузку
  - Распределение более равномерное, чем при использовании 1000 vnode на один узел в консистентном хешировании

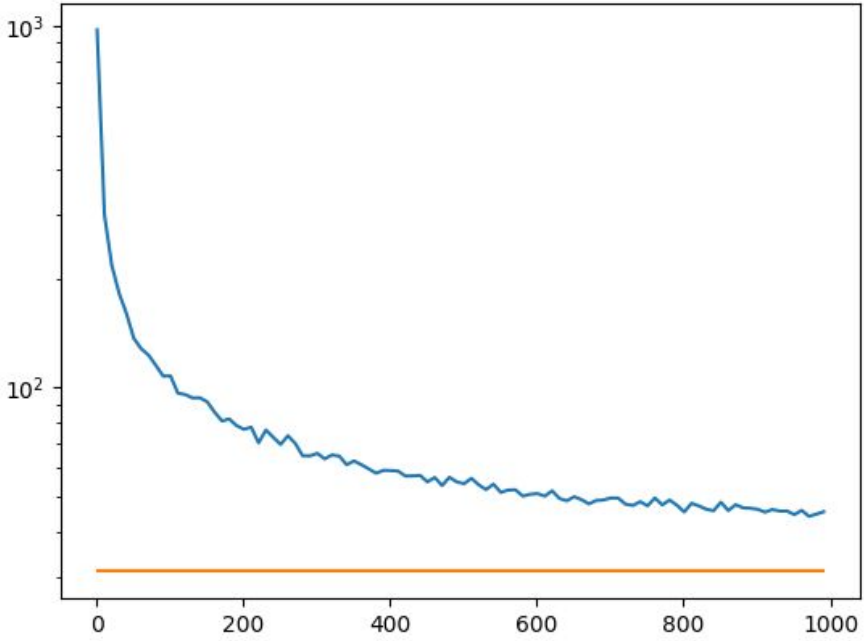

Что почитать

- *Fagin R. et al.* Extendible hashing—a fast access method for dynamic files
- *Thaler D., Ravishankar C. V.* A name-based mapping scheme for rendezvous
- *Karger D. et al.* Consistent hashing and random trees: Distributed caching protocols for relieving hot spots on the world wide web
- *Appleton B., O'Reilly M.* Multi-probe consistent hashing
- *Lamping J., Veach E.* A fast, minimal memory, consistent hash algorithm
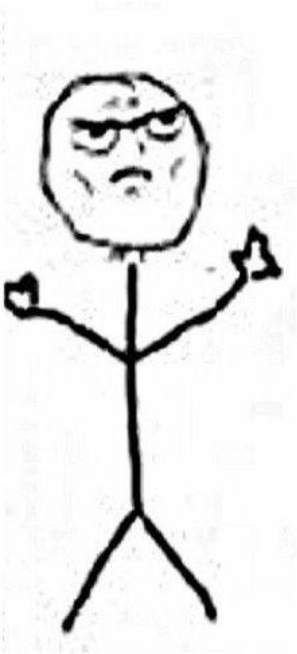
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание
спасибо за внимание